UNIVERSIDADE FEDERAL DO PIAUÍ
CENTRO DE CIÊNCIAS DA SAÚDE – CCS
PROGRAMA DE PÓS-GRADUAÇÃO EM ENFERMAGEM – PPGENF
DOUTORADO EM ENFERMAGEM

LÁISA REBECCA SOUSA CARVALHO

DESENVOLVIMENTO DE MODELOS DE INTELIGÊNCIA ARTIFICIAL PARA PREDIÇÃO DE SEPSE TARDIA EM UNIDADE DE TERAPIA INTENSIVA NEONATAL

Teresina

2026
LÁISA REBECCA SOUSA CARVALHO

DESENVOLVIMENTO DE MODELOS DE INTELIGÊNCIA ARTIFICIAL PARA PREDIÇÃO DE SEPSE TARDIA EM UNIDADE DE TERAPIA INTENSIVA NEONATAL

Projeto de tese apresentado ao Programa de Pós-Graduação em Enfermagem, como pré-requisito para Submissão ao Comitê de Ética em Pesquisa (CEP).

Área de Concentração
Enfermagem no Contexto Social Brasileiro.

Linha de Pesquisa
Políticas e Práticas Socioeducativas em Enfermagem.

Orientadora
Profª. Drª. Lidya Tolstenko Nogueira.

Coorientador
Prof. Dr. Vinícius Ponte Machado.

Teresina

2026

RESUMO

CARVALHO, L. R. S. **Desenvolvimento de modelos de inteligência artificial para predição de sepse tardia em Unidade de Terapia Intensiva Neonatal.** 2026. 65f. Tese (Doutorado em Enfermagem) - Universidade Federal do Piauí, Teresina, 2026.

Introdução: a sepse neonatal tardia, definida pelo início das manifestações após 72 horas de vida, constitui importante causa de morbimortalidade em recém-nascidos internados em Unidades de Terapia Intensiva Neonatal (UTIN), com diagnóstico dificultado pela inespecificidade dos sinais clínicos e pelas limitações da hemocultura. A inteligência artificial, por meio de algoritmos de aprendizado de máquina, desponta como estratégia promissora para a predição precoce do desfecho. **Objetivo:** desenvolver e avaliar algoritmos de inteligência artificial para a predição de sepse tardia em recém-nascidos internados em UTIN de maternidade pública de referência em alta complexidade no Nordeste do Brasil. **Método:** estudo de coorte retrospectivo fundamentado em técnicas de aprendizado de máquina, conduzido a partir de prontuários eletrônicos de recém-nascidos internados em UTIN de hospital público de referência no Piauí. A variável-alvo é a ocorrência de sepse neonatal tardia (CID-10 A41.9 e P36), e as variáveis preditoras compreendem dados demográficos, clínicos, laboratoriais, microbiológicos e escores clínicos. Serão treinados e comparados diferentes algoritmos de classificação, com avaliação de desempenho por métricas como acurácia, sensibilidade, especificidade e área sob a curva ROC, e análise de explicabilidade. O projeto será submetido à apreciação do Comitê de Ética em Pesquisa, em conformidade com a Resolução nº 466/2012 do Conselho Nacional de Saúde e com a Lei Geral de Proteção de Dados Pessoais. **Resultados esperados:** identificação das variáveis preditoras de maior relevância e construção de modelo preditivo de bom desempenho, com vistas à proposição de protótipo de sistema de apoio à decisão clínica para alerta precoce de sepse tardia na UTIN. **Conclusão:** espera-se contribuir para o avanço do conhecimento científico nacional e para a melhoria das práticas assistenciais em neonatologia no âmbito do Sistema Único de Saúde.

Palavras-chave: Sepse Neonatal; Inteligência Artificial; Aprendizado de Máquina; Unidades de Terapia Intensiva Neonatal; Recém-Nascido.

ABSTRACT

CARVALHO, L. R. S. **Development of Artificial Intelligence Models for Predicting Late-Onset Sepsis in a Neonatal Intensive Care Unit.** 2026. 65f. Tese (Doutorado em Enfermagem) - Universidade Federal do Piauí, Teresina, 2026.

Introduction: late-onset neonatal sepsis, defined by the onset of clinical manifestations after 72 hours of life, is a major cause of morbidity and mortality among newborns admitted to Neonatal Intensive Care Units (NICU); its diagnosis is hindered by the nonspecific clinical signs and the limitations of blood culture. Artificial intelligence, through machine learning algorithms, has emerged as a promising strategy for the early prediction of this outcome. **Objective:** to develop and evaluate artificial intelligence algorithms for predicting late-onset sepsis in newborns admitted to the NICU of a public high-complexity referral maternity hospital in Northeastern Brazil. **Methods:** retrospective cohort study based on machine learning techniques, conducted using electronic health records of newborns admitted to the NICU of a public referral hospital in Piauí. The target variable is the occurrence of late-onset neonatal sepsis (ICD-10 A41.9 and P36), and the predictor variables comprise demographic, clinical, laboratory, microbiological data and clinical scores. Different classification algorithms will be trained and compared, with performance assessed through metrics such as accuracy, sensitivity, specificity and the area under the ROC curve, along with explainability analysis. The project will be submitted to the Research Ethics Committee, in compliance with Resolution No. 466/2012 of the National Health Council and with the General Personal Data Protection Law. **Expected results:** identification of the most relevant predictor variables and construction of a high-performance predictive model, aiming at the proposal of a clinical decision support system prototype for early warning of late-onset sepsis in the NICU. **Conclusion:** the study is expected to contribute to the advancement of national scientific knowledge and to the improvement of neonatal care practices within the Brazilian Unified Health System.

Keywords: Neonatal Sepsis; Artificial Intelligence; Machine Learning; Intensive Care Units, Neonatal; Infant, Newborn.

RESUMEN

CARVALHO, L. R. S. **Desarrollo de Modelos de Inteligencia Artificial para la Predicción de la Sepsis de Inicio Tardío en una Unidad de Cuidados Intensivos Neonatales.** 2026. 65f. Tese (Doutorado em Enfermagem) - Universidade Federal do Piauí, Teresina, 2026.

Introducción: la sepsis neonatal tardía, definida por el inicio de las manifestaciones clínicas después de las 72 horas de vida, constituye una importante causa de morbimortalidad en recién nacidos ingresados en Unidades de Cuidados Intensivos Neonatales (UCIN); su diagnóstico se ve dificultado por la inespecificidad de los signos clínicos y por las limitaciones del hemocultivo. La inteligencia artificial, mediante algoritmos de aprendizaje automático, surge como una estrategia prometedora para la predicción precoz de este desenlace. **Objetivo:** desarrollar y evaluar algoritmos de inteligencia artificial para la predicción de sepsis tardía en recién nacidos ingresados en la UCIN de una maternidad pública de referencia de alta complejidad en el Nordeste de Brasil. **Método:** estudio de cohorte retrospectivo fundamentado en técnicas de aprendizaje automático, realizado a partir de historias clínicas electrónicas de recién nacidos ingresados en la UCIN de un hospital público de referencia en Piauí. La variable objetivo es la ocurrencia de sepsis neonatal tardía (CIE-10 A41.9 y P36), y las variables predictoras comprenden datos demográficos, clínicos, de laboratorio, microbiológicos y escalas clínicas. Se entrenarán y compararán diferentes algoritmos de clasificación, con evaluación del desempeño mediante métricas como exactitud, sensibilidad, especificidad y área bajo la curva ROC, además del análisis de explicabilidad. El proyecto será sometido a la apreciación del Comité de Ética en Investigación, en conformidad con la Resolución n.º 466/2012 del Consejo Nacional de Salud y con la Ley General de Protección de Datos Personales. **Resultados esperados:** identificación de las variables predictoras de mayor relevancia y construcción de un modelo predictivo de buen desempeño, con miras a la propuesta de un prototipo de sistema de apoyo a la decisión clínica para la alerta precoz de sepsis tardía en la UCIN. **Conclusión:** se espera contribuir al avance del conocimiento científico nacional y a la mejora de las prácticas asistenciales en neonatología en el ámbito del Sistema Único de Salud.

Palabras clave: Sepsis Neonatal; Inteligencia Artificial; Aprendizaje Automático; Unidades de Cuidado Intensivo Neonatal; Recién Nacido.

LISTA DE ILUSTRAÇÕES

Figura 1 – Fluxograma de partição da amostra pelo Método Holdout (70/30%) para o teste piloto 41
Figura 2 – Fluxograma das etapas do processo de Descoberta de Conhecimento em Bases de Dados (KDD). 42
Figura 3 – Fluxograma do percurso metodológico do estudo, organizado segundo o processo KDD. 46

LISTA DE QUADROS E TABELAS

Quadro 1 – Etapas do processo de Descoberta de Conhecimento em Bases de Dados (KDD). 35
Quadro 2 – Variáveis demográficas e do parto e as variáveis clínicas e de internação. 38
Quadro 3 – Variáveis laboratoriais, variáveis microbiológicas e os escores clínicos. 40
Quadro 4 – Algoritmos de aprendizado de máquina a serem testados. 44
Quadro 5 – Métricas de avaliação de desempenho dos modelos. 45
Quadro 6 – Cronograma de execução das atividades. 47

Tabela 1 – Orçamento para execução do projeto. 48

LISTA DE ABREVIATURAS E SIGLAS

AUROC	– Área Sob a Curva ROC (*Area Under the ROC Curve*)
CEP	– Comitê de Ética em Pesquisa
CID-10	– Classificação Internacional de Doenças, 10ª Revisão
CNS	– Conselho Nacional de Saúde
DATASUS	– Departamento de Informática do Sistema Único de Saúde
DT	– Árvore de Decisão (*Decision Tree*)
GB	– *Gradient Boosting*
IA	– Inteligência Artificial
IT	– Relação Neutrófilos Imaturos/Totais
KDD	– *Knowledge Discovery in Databases*
KNN	– K-Vizinhos Mais Próximos (*K-Nearest Neighbors*)
LGPD	– Lei Geral de Proteção de Dados Pessoais
ML	– Aprendizado de Máquina (*Machine Learning*)
MS	– Ministério da Saúde
NB	– *Naive Bayes*
NMDER	– Nova Maternidade Dona Evangelina Rosa
OMS	– Organização Mundial da Saúde
PCR	– Proteína C Reativa / Reação em Cadeia da Polimerase
PCT	– Procalcitonina
PE	– Prontuário Eletrônico
POP	– Procedimento Operacional Padronizado
RBPN	– Rede Brasileira de Pesquisas Neonatais
RF	– Floresta Aleatória (*Random Forest*)
RL	– Regressão Logística
RN	– Recém-Nascido
ROC	– *Receiver Operating Characteristic*
SIM	– Sistema de Informações sobre Mortalidade
SUS	– Sistema Único de Saúde
TCLE	– Termo de Consentimento Livre e Esclarecido

TREWScore – *Targeted Real-Time Early Warning Score*
UFPI – Universidade Federal do Piauí
UNESP – Universidade Estadual Paulista
UTIN – Unidade de Terapia Intensiva Neonatal
WHO – *World Health Organization*
XAI – *Explainable Artificial Intelligence*
XGBoost – *Extreme Gradient Boosting*

SUMÁRIO

1 INTRODUÇÃO 12

1.1 CONTEXTUALIZAÇÃO DO PROBLEMA 12

1.2 OBJETO DO ESTUDO 14

1.3 QUESTÃO DE PESQUISA 14

1.4 HIPÓTESE 14

1.5 JUSTIFICATIVA E RELEVÂNCIA 15

1.6 OBJETIVOS 15

1.6.1 Objetivo Geral 15

1.6.2 Objetivos Específicos 16

2 REFERENCIAL TEMÁTICO 17

2.1 SEPSE NEONATAL: DEFINIÇÃO, FISIOPATOLOGIA E EPIDEMIOLOGIA 17

2.2 INTELIGÊNCIA ARTIFICIAL E APRENDIZADO DE MÁQUINA EM SAÚDE APLICADA À PREDIÇÃO E AO DIAGNÓSTICO DA SEPSE NEONATAL TARDIA 25

2.2.1 Inteligência artificial explicável (XAI) e interpretabilidade clínica 27

2.2.2 Inteligência artificial na predição de sepse em UTI 29

2.2.3 Escores clínicos aplicados à avaliação do recém-nascido: adaptação neonatal da Escala de Coma de Glasgow, NEWS2, qSOFA e nSOFA 32

2.3 O PROCESSO DE DESCOBERTA DE CONHECIMENTO EM BASES DE DADOS (KDD) 34

3 METODOLOGIA 36

3.1 TIPO DE ESTUDO 36

3.2 LOCAL E PARTICIPANTES DO ESTUDO 36

3.3 CRITÉRIOS DE INCLUSÃO E EXCLUSÃO 37

3.4 VARIÁVEL-ALVO 38

3.5 VARIÁVEIS PREDITORAS 38
3.5.1 Variáveis demográficas e do parto e variáveis clínicas e de internação ... 38
3.5.2 Variáveis Laboratoriais 39
3.6 TREINAMENTO PARA A COLETA DE DADOS E TESTE PILOTO 40
3.7 COLETA DE DADOS E PROCESSO KDD 41
3.8 ALGORITMOS DE APRENDIZADO DE MÁQUINA 43
3.9 TREINAMENTO, VALIDAÇÃO E MÉTRICAS DE DESEMPENHO 44
3.10 ASPECTOS ÉTICOS 46
4 CRONOGRAMA 47
5 ORÇAMENTO 48
REFERÊNCIAS 49
APÊNDICE A – INSTRUMENTO DE COLETA DE DADOS DOS PRONTUÁRIOS ELETRÔNICOS 58

1 INTRODUÇÃO

1.1 CONTEXTUALIZAÇÃO DO PROBLEMA

A sepse neonatal configura-se como um dos mais graves desafios da saúde perinatal, representando uma das principais causas de morbidade e mortalidade em recém-nascidos (RN) internados em Unidades de Terapia Intensiva Neonatal (UTIN). Trata-se de uma síndrome inflamatória sistêmica decorrente de uma resposta desregulada do organismo imaturo à infecção, que pode resultar em disfunção orgânica múltipla, choque séptico e óbito quando não diagnosticada e tratada precocemente (Celik *et al*., 2022).

A Organização Mundial da Saúde (OMS) estimou que, em 2019, a sepse foi responsável por aproximadamente 550.000 mortes neonatais em todo o mundo, evidenciando a magnitude global do problema (WHO, 2021). No Brasil, a atenção ao recém-nascido no período perinatal é estruturada, no âmbito do Sistema Único de Saúde (SUS), pela Rede Alyne (Portaria GM/MS nº 5.350/2024), que reformulou a Rede Cegonha com o objetivo de reduzir a morbimortalidade materna e infantil e enfrentar as desigualdades regionais e étnico-raciais. Entre suas medidas voltadas ao neonato grave, destacam-se a ampliação do financiamento e a habilitação de leitos de UTIN (Brasil, 2024). Tais políticas, contudo, concentram-se na estruturação de fluxos e no financiamento, permanecendo escassas as ferramentas tecnológicas de apoio à decisão clínica voltadas à predição precoce de desfechos na UTIN, o que dificulta intervenções oportunas, a estratificação de risco em tempo real e a adoção de estratégias baseadas em evidências.

Dados do Sistema de Informações de Mortalidade (SIM), disponibilizados pelo Departamento de Informação e Informática do Sistema Único de Saúde do Brasil (DATASUS) em 2024, revelaram que, no ano de 2022, foram registrados 1.118 óbitos por septicemia bacteriana em recém-nascidos entre zero e seis dias de vida e 1.028 entre sete e 27 dias de vida, configurando a sepse neonatal como a quinta maior causa de óbitos neonatais precoces e tardios no país, sendo responsável por índices variáveis de 9% a 31% dos óbitos (Brito *et al*., 2024; DATASUS, 2024).

A sepse neonatal é dividida em dois subtipos conforme o momento de aparecimento. A sepse precoce, que se manifesta até 72 horas de vida e está associada a fatores maternos, e a sepse tardia, que surge após 72 horas de vida e está fortemente vinculada a fatores ambientais e hospitalares. A sepse tardia ocorre predominantemente em prematuros internados em UTIN, nos quais a imaturidade imunológica, o baixo peso ao nascer e o uso de dispositivos invasivos

criam condições propícias para a colonização e invasão por patógenos hospitalares (Malaquias *et al*., 2022; Conceição *et al*., 2024).

A Rede Brasileira de Pesquisas Neonatais (RBPN), que desde 1997 acompanha prematuros de muito baixo peso em centros universitários de referência, identificou, no início de suas atividades, uma incidência de sepse tardia de até 25% nessa população. O Projeto DownLOS, coordenado por pesquisadoras da Universidade Estadual Paulista (UNESP) e executado por 12 centros da RBPN entre 2021 e 2023, demonstrou ser possível reduzir essa incidência em 18,5% com a adoção de pacotes de cuidado baseados em evidências. Porém, o problema permanece longe de ser erradicado, especialmente em hospitais públicos das regiões Norte e Nordeste do Brasil (Rugolo; Bentlin, 2026).

O diagnóstico precoce da sepse tardia em neonatos é particularmente desafiador. A apresentação clínica é frequentemente inespecífica, com sinais sutis como instabilidade térmica, letargia, intolerância alimentar e apneia, que podem mimetizar outras condições clínicas do período neonatal. O padrão-ouro diagnóstico é a hemocultura positiva, porém este exame apresenta demora de 24 a 72 horas para o resultado definitivo, além de falsos negativos em até 30% dos casos (Procianoy; Silveira, 2020; De Rose *et al*., 2024). Essa incerteza diagnóstica leva, muitas vezes, ao início empírico de antibioticoterapia de amplo espectro, contribuindo no desenvolvimento de resistência bacteriana e alterações deletérias no prematuro.

Nesse contexto, a inteligência artificial (IA), especialmente os algoritmos de aprendizado de máquina, surge como abordagem promissora para a predição precoce da sepse neonatal tardia, permitindo a análise integrada de múltiplas variáveis clínicas, laboratoriais e de sinais vitais em tempo real. Estudos recentes demonstraram que modelos baseados em Random Forest, Gradient Boosting e XGBoost, treinados com dados de prontuários eletrônicos e monitores de beira de leito, são capazes de predizer a sepse tardia com antecedência de até 48 horas antes de sua manifestação clínica (Van Den Berg *et al*., 2023; Shu *et al*., 2025).

A revisão sistemática de Sullivan, Kausch e Fairchild (2023) destacou que prematuros internados em UTIN representam a população ideal para a aplicação de modelos preditivos baseados em IA, por constituírem um grupo relativamente homogêneo, submetido a monitoramento contínuo e com alto potencial de retorno sobre o investimento em função da longa expectativa de vida. A integração de dados cardiorrespiratórios com parâmetros laboratoriais e demográficos tem mostrado os melhores resultados preditivos (Kausch *et al*., 2023; Peng *et al*., 2023).

No Brasil, apesar do crescente interesse na aplicação de IA em saúde e das recomendações do Ministério da Saúde (MS) para o uso de algoritmos preditivos em UTI, pesquisas voltadas especificamente para a predição de sepse neonatal tardia em UTIN públicas são escassas. A maior parte dos estudos disponíveis foi conduzida em instituições privadas de alta renda ou em bases de dados internacionais que não refletem a realidade epidemiológica, microbiológica e assistencial das maternidades públicas brasileiras (Bezerra *et al*., 2023).

Diante desse cenário, este projeto propõe o desenvolvimento de algoritmos de inteligência artificial para predição de sepse tardia em pacientes internados em Unidade de Terapia Intensiva Neonatal de hospital público de referência em alta complexidade no Piauí, contribuindo para o avanço do conhecimento científico nacional e para a melhoria das práticas assistenciais em neonatologia.

1.2 OBJETO DO ESTUDO

O objeto deste estudo é a predição da sepse neonatal tardia em recém-nascidos internados em Unidade de Terapia Intensiva Neonatal.

1.3 QUESTÃO DE PESQUISA

Algoritmos de inteligência artificial, treinados com aprendizado de máquina em prontuários eletrônicos, são capazes de predizer, com desempenho adequado, a ocorrência de sepse tardia em recém-nascidos internados em Unidade de Terapia Intensiva Neonatal?

1.4 HIPÓTESE

A partir da questão formulada, admitem-se as seguintes hipóteses:

H_1 - Algoritmos de inteligência artificial, treinados com aprendizado de máquina em dados de prontuários eletrônicos, são capazes de predizer a ocorrência de sepse tardia em recém-nascidos internados em Unidade de Terapia Intensiva Neonatal com desempenho preditivo adequado.

H_2 - Algoritmos de inteligência artificial, treinados com aprendizado de máquina em dados de prontuários eletrônicos, não são capazes de predizer a ocorrência de sepse tardia em

recém-nascidos internados em Unidade de Terapia Intensiva Neonatal com desempenho preditivo adequado.

1.5 JUSTIFICATIVA E RELEVÂNCIA

A literatura científica nacional e internacional sobre o tema ainda apresenta lacunas significativas que justificam o desenvolvimento deste estudo. No Brasil, poucos estudos foram identificados no qual desenvolvam e avaliem algoritmos de inteligência artificial especificamente voltados para a predição de sepse tardia em recém-nascidos internados em Unidades de Terapia Intensiva Neonatal de instituições públicas, constituindo uma lacuna científica expressiva frente à magnitude do problema no setor público de saúde.

Os estudos internacionais existentes foram conduzidos predominantemente em hospitais privados de países de alta renda, com infraestrutura tecnológica avançada e perfis epidemiológicos, microbiológicos e assistenciais distintos da realidade brasileira. Essa diferença de contexto limita e excedem dos modelos desenvolvidos nesses estudos para as UTIN do SUS, especialmente nas regiões Norte e Nordeste do país, onde as desigualdades no acesso a recursos diagnósticos e terapêuticos são mais evidentes.

Há ainda poucos estudos que comparem sistematicamente diferentes algoritmos de aprendizado de máquina na predição de sepse tardia neonatal, utilizando variáveis clínicas, laboratoriais e de sinais vitais disponíveis rotineiramente em UTIN públicas brasileiras de alta complexidade. A maioria das pesquisas nacionais sobre predição de sepse por meio de algoritmos foi realizada em populações adultas ou mistas, não abordando as particularidades fisiológicas e epidemiológicas do recém-nascido prematuro.

A limitação ou ausência de ferramentas de apoio à decisão clínica validadas para esse contexto resulta em diagnósticos tardios, tratamentos empíricos desnecessariamente prolongados e maior morbimortalidade neonatal por sepse tardia. Diante dessas lacunas, este estudo se propõe a gerar evidências científicas originárias do contexto público brasileiro, contribuindo para a melhoria da qualidade assistencial em neonatologia e para o fortalecimento da pesquisa em saúde digital no SUS.

1.6 OBJETIVOS

1.6.1 Objetivo Geral

- Desenvolver modelos de inteligência artificial para predição de sepse tardia em recém-nascidos internados em Unidade de Terapia Intensiva Neonatal de uma maternidade pública de referência em alta complexidade no Nordeste do Brasil.

1.6.2 Objetivos Específicos

- Identificar variáveis clínicas, laboratoriais, microbiológicas e de sinais vitais associadas à ocorrência de sepse tardia neonatal nos prontuários eletrônicos da UTIN estudada;
- Identificar as variáveis preditoras de maior importância para os modelos de melhor desempenho, utilizando técnicas de explicabilidade;
- Propor protótipo de sistema de apoio à decisão clínica para o monitoramento e alerta precoce de sepse tardia na UTIN, com base no algoritmo de melhor desempenho.

1 REFERENCIAL TEMÁTICO

1.1 SEPSE NEONATAL: DEFINIÇÃO, FISIOPATOLOGIA E EPIDEMIOLOGIA

A sepse neonatal constitui uma das condições clínicas mais relevantes da saúde perinatal, integrando, ao lado da prematuridade, como uma das principais causas de morbimortalidade em recém-nascidos em todo o mundo (Strunk *et al.*, 2024). Apresenta importância epidemiológica, com implicações diretas sobre a inconsistência diagnóstica, a heterogeneidade na coleta de dados e a adequação das condutas terapêuticas (Molloy *et al.*, 2020; Strunk *et al.*, 2024).

De maneira geral, a sepse neonatal é compreendida como uma síndrome clínica caracterizada por manifestações sistêmicas de infecção, associada ou não à recuperação de um agente patogênico em hemocultura ou em outro fluido corporal estéril, durante os primeiros 28 dias de vida (Shane; Sánchez; Stoll, 2017; Procianoy; Silveira, 2020).

A literatura científica classifica a doença, de acordo com o momento de início das manifestações clínicas, em sepse neonatal precoce e sepse neonatal tardia. A sepse precoce decorre, em sua maioria, da transmissão vertical de microrganismos do trato geniturinário materno e manifesta-se nas primeiras setenta e duas horas de vida, embora alguns autores e protocolos assistenciais adotem o ponto de corte de quarenta e oito horas. A sepse tardia, por sua vez, está habitualmente relacionada à aquisição horizontal de patógenos do ambiente hospitalar ou comunitário e ocorre após esse período (Shane; Sánchez; Stoll, 2017; Raturi; Chandran, 2024; De Rose *et al.*, 2024).

As Definições do Terceiro Consenso Internacional para Sepse e Choque Séptico (Sepsis-3), que conceituam a sepse no adulto como disfunção orgânica ameaçadora à vida secundária a uma resposta desregulada do hospedeiro à infecção, não foram validadas para a população neonatal (Singer *et al.*, 2016).

De modo análogo, os Critérios Internacionais de Consenso para Sepse e Choque Séptico Pediátricos, fundamentados no escore de Phoenix e publicados em 2024, excluem

explicitamente os recém-nascidos pré-termo com menos de trinta e sete semanas de idade gestacional, reiterando a necessidade de critérios específicos para o neonato (Schlapbach *et al.*, 2024; Sanchez-Pinto *et al.*, 2024).

Tal lacuna foi reiterada pela atualização das diretrizes da *Surviving Sepsis Campaign* para o manejo da sepse e do choque séptico em crianças, publicada em 2026, cuja aplicabilidade se restringe a pacientes com idade gestacional ao nascimento igual ou superior a trinta e sete semanas e até dezoito anos de idade, excluindo de modo explícito os recém-nascidos pré-termo, justamente a população de maior risco para a forma tardia da doença (Weiss *et al.*, 2026). Nessa direção, autores de referência têm defendido, de forma reiterada, a construção de uma definição consensual neonatal-específica, capaz de contemplar a heterogeneidade da apresentação clínica e a influência da idade gestacional sobre a resposta do hospedeiro (Wynn, 2016; Wynn *et al.*, 2014; Mcgovern *et al.*, 2020).

Do ponto de vista fisiopatológico, a sepse neonatal resulta da interação complexa entre a virulência do agente infeccioso e a resposta imunoinflamatória de um hospedeiro imunologicamente imaturo. O sistema imune do recém-nascido, sobretudo o do prematuro, apresenta limitações funcionais relevantes tanto no componente inato quanto no adaptativo (Strunk *et al.*, 2024). Entre tais limitações, destacam-se a reduzida reserva e a função quimiotática e fagocitária comprometida dos neutrófilos, a menor atividade do sistema complemento, a deficiência relativa de imunoglobulinas, uma vez que a transferência placentária de imunoglobulina-G materna ocorre predominantemente no terceiro trimestre, o que torna o pré-termo particularmente desprotegido, e a sinalização imatura mediada por receptores de reconhecimento de padrões, como os receptores do tipo Toll (Procianoy; Silveira, 2020; Strunk *et al.*, 2024).

Diante da invasão microbiana, o reconhecimento de padrões moleculares associados a patógenos desencadeia a ativação de vias de sinalização intracelular e a liberação de mediadores pró-inflamatórios, com destaque para as interleucinas 1-beta, 6 e 8 e o fator de necrose tumoral alfa. A produção desses mediadores, embora essencial ao combate ao agente infeccioso, pode evoluir para uma resposta inflamatória sistêmica desregulada, com lesão endotelial, aumento da permeabilidade vascular, disfunção microcirculatória, ativação da cascata da coagulação e instabilidade hemodinâmica (Silveira; Procianoy, 2012; Procianoy; Silveira, 2020). A progressão desse processo culmina em hipoperfusão tecidual, choque séptico e disfunção de múltiplos órgãos e sistemas, condições associadas à elevada letalidade no período neonatal (Shane; Sánchez; Stoll, 2017).

Ademais, merece particular atenção a repercussão da resposta inflamatória sobre o sistema nervoso central em desenvolvimento. A lesão neurológica associada à sepse neonatal pode decorrer tanto da citotoxicidade bacteriana direta, em casos de meningite, quanto da inflamação sistêmica e da instabilidade hemodinâmica, mesmo na ausência de invasão do parênquima encefálico. A substância branca do prematuro mostra-se especialmente vulnerável à injúria de oligodendrócitos e à maturação atípica diante de cascatas inflamatórias, o que se traduz em risco aumentado de comprometimento do neurodesenvolvimento a longo prazo (Coggins; Glaser, 2022; Strunk *et al.*, 2024).

Assim, a sepse neonatal representa um relevante problema de saúde pública global. Estimativas derivadas do Estudo de Carga Global de Doenças apontam para a ocorrência de aproximadamente 1.300.000 casos incidentes anuais de sepse neonatal e outras infecções neonatais, com cerca de 203.000 mortes atribuíveis à sepse, sendo a maior parte da carga concentrada em países de baixa e média renda (Fleischmann *et al.*, 2021). Revisões sistemáticas confirmam que a incidência da sepse neonatal varia amplamente entre regiões e que a doença responde por parcela substancial da mortalidade neonatal evitável, com aproximadamente 99,0% dos óbitos ocorrendo em contextos de menor disponibilidade de recursos (Fleischmann-Struzek *et al.*, 2018; Fleischmann *et al.*, 2021).

Análises mais recentes, fundamentadas no Estudo de Carga Global de Doenças de 2021, evidenciam tendência de redução das taxas padronizadas de incidência, prevalência, mortalidade e anos de vida ajustados por incapacidade atribuíveis à sepse neonatal e a outras infecções neonatais entre 1990 e 2021, ainda que a carga permaneça desproporcionalmente elevada na África e no Sudeste Asiático (Mu *et al.*, 2025).

O estudo observacional global NeoOBS, conduzido em 19 hospitais de 11 países, evidenciou a magnitude do problema ao documentar mortalidade global de 11,3% entre neonatos com sepse suspeita, número que se elevou a 17,7% nos casos com hemocultura positiva para patógeno; acrescenta-se que, mais da metade dos óbitos relacionados à infecção decorreu de infecções de aquisição hospitalar, isto é, de etiologia tardia (Russell *et al.*, 2023). Esse achado reforça a centralidade da sepse neonatal tardia no panorama da morbimortalidade neonatal, sobretudo no contexto da progressiva sobrevida de recém-nascidos extremamente prematuros e de muito baixo peso (Coggins; Glaser, 2022).

A epidemiologia da sepse neonatal tardia caracteriza-se por uma relação inversa consistente entre a incidência da doença e a idade gestacional e o peso ao nascer. Estudos populacionais de larga escala demonstram que a sepse tardia acomete proporção expressiva dos

recém-nascidos pré-termo extremos, podendo atingir até um quinto dos neonatos com menos de 28 semanas de idade gestacional em países de alta renda (Klinger *et al.*, 2024; Huncikova *et al.*, 2023). Dados da Rede Neonatal Alemã e de coortes populacionais norueguesas corroboram esse gradiente e evidenciam, ainda, que a redução da incidência da sepse precoce, favorecida pela profilaxia antibiótica intraparto, não se acompanhou de declínio equivalente da forma tardia, cuja frequência tende a se manter ou a aumentar em paralelo à maior sobrevida dos prematuros (Klinger *et al.*, 2024; Huncikova *et al.*, 2023).

Quanto ao perfil etiológico, observa-se variação geográfica significativa. Em países de alta renda, predominam os patógenos Gram-positivos, com destaque para os estafilococos coagulase-negativos, responsáveis por mais da metade das bacteremias de início tardio em prematuros, seguidos por *Staphylococcus aureus*. Em países de baixa e média renda, por outro lado, prevalecem os bacilos Gram-negativos, notadamente *Klebsiella pneumoniae*, *Escherichia coli* e *Acinetobacter baumannii*, além de relevante contribuição de *Candida* spp. nos recém-nascidos de muito baixo peso (Russell *et al.*, 2023; Coggins; Glaser, 2022; Strunk *et al.*, 2024). Esse cenário é agravado pela expansão da resistência antimicrobiana, fenômeno que ameaça a efetividade dos esquemas terapêuticos disponíveis e que motivou a inclusão de patógenos prioritários na lista atualizada da Organização Mundial da Saúde, em 2024 (World Health Organization, 2024; Russell *et al.*, 2023).

Os fatores de risco para a sepse neonatal tardia encontram-se amplamente caracterizados na literatura e relacionam-se, em grande medida, à imaturidade do hospedeiro e à exposição a procedimentos assistenciais invasivos. A prematuridade e o muito baixo e extremo baixo peso ao nascer constituem os determinantes de maior peso, dada a fragilidade das barreiras cutâneo-mucosas e a imaturidade imunológica que lhes são inerentes (Raturi; Chandran, 2024; Strunk *et al.*, 2024). A esses, somam-se fatores iatrogênicos e relacionados ao cuidado intensivo neonatal (Raturi; Chandran, 2024; De Rose *et al.*, 2024) e as comorbidades próprias da prematuridade, bem como a privação do leite materno, também figuram de modo consistente como condições predisponentes (Raturi; Chandran, 2024). O reconhecimento desse conjunto de fatores possui implicações práticas diretas, na medida em que orienta estratégias de prevenção, de vigilância epidemiológica e de racionalização do uso de antimicrobianos nas UTINs (Stocker *et al.*, 2024).

O diagnóstico da sepse neonatal tardia permanece um dos maiores desafios da neonatologia, em razão da inespecificidade e da sutileza das manifestações clínicas e da limitação dos métodos laboratoriais disponíveis (Strunk *et al.*, 2024; De Rose *et al.*, 2024). As

manifestações clínicas iniciais costumam ser discretas e pouco específicas, sobrepondo-se a outras condições próprias do período neonatal, e incluem instabilidade térmica, apneia, bradicardia, intolerância alimentar, letargia ou irritabilidade, desconforto respiratório, alterações da perfusão periférica e instabilidade hemodinâmica (Shane; Sánchez; Stoll, 2017; Procianoy; Silveira, 2020). Essa apresentação heterogênea explica, em grande parte, a tendência à instituição liberal de antibioticoterapia empírica diante da suspeita clínica, conduta que, embora pretenda proteger uma população vulnerável, contribui para a pressão seletiva de microrganismos multirresistentes (Raturi; Chandran, 2024).

A hemocultura é reconhecida como o padrão-ouro para a confirmação diagnóstica da sepse neonatal, por permitir a identificação do agente etiológico e a determinação de seu perfil de sensibilidade aos antimicrobianos (Shane; Sánchez; Stoll, 2017; Strunk *et al.*, 2024). Entretanto, o método apresenta limitações no contexto neonatal, entre as quais o volume reduzido de sangue habitualmente coletado, a baixa densidade de unidades formadoras de colônias na bacteremia neonatal, a exposição prévia a antimicrobianos, materna ou do próprio recém-nascido, e o tempo necessário para a positividade do exame (De Rose *et al.*, 2024).

Estudos sobre o tempo de positividade demonstram que a maioria das hemoculturas verdadeiramente positivas na bacteremia tardia tende a se positivar nas primeiras 24 a 36 horas de incubação, informação de relevância prática para a duração da antibioticoterapia empírica e para a decisão de suspensão precoce de antimicrobianos em casos não confirmados (Willey *et al.*, 2025). Adicionalmente, a coleta de volume adequado e, quando possível, de amostras de mais de um sítio tem sido recomendada como estratégia para aumentar a sensibilidade do método (Coggins; Glaser, 2022).

Em face das limitações da hemocultura e da necessidade de decisões terapêuticas tempestivas, diversos biomarcadores têm sido incorporados à investigação diagnóstica como exames complementares. A proteína C-reativa (PCR) é o marcador de fase aguda mais amplamente utilizado, embora sua elevação ocorra de forma tardia em relação ao início da infecção, o que limita seu valor isolado no diagnóstico precoce e justifica sua dosagem seriada (De Rose *et al.*, 2024).

A procalcitonina apresenta cinética mais favorável, com elevação mais precoce, e tem demonstrado bom desempenho diagnóstico, sobretudo quando interpretada em associação a outros marcadores; revisões sistemáticas reforçam o potencial da procalcitonina, isoladamente ou combinada à PCR, embora ressaltem a ausência de um biomarcador ideal (De Rose *et al.*, 2024). Outros marcadores, como a interleucina-6, a presepsina e a expressão do CD64 em

neutrófilos, além de índices hematológicos, em particular a relação entre neutrófilos imaturos e neutrófilos totais e a trombocitopenia, têm sido investigados como ferramentas auxiliares, isoladamente ou no âmbito de escores hematológicos compostos (Silveira; Procianoy, 2012; De Rose *et al.*, 2024).

Quando há suspeita de comprometimento do sistema nervoso central, a punção lombar com análise do líquido cefalorraquidiano é recomendada, dada a frequência não desprezível de meningite associada à sepse tardia e suas implicações prognósticas; a urocultura, por sua vez, possui valor no diagnóstico de infecção de origem nosocomial no recém-nascido com sepse tardia (Procianoy; Silveira, 2020; De Rose *et al.*, 2024).

É importante destacar que a atualização de 2026 das diretrizes da *Surviving Sepsis Campaign* para crianças passou a sugerir, como recomendação condicional de moderada certeza de evidência, que a procalcitonina não seja empregada de modo rotineiro para orientar a desescalonação antimicrobiana em serviços que disponham de programas efetivos de gerenciamento de antimicrobianos, ponderando-se que o marcador agrega custo sem benefício consistente sobre a mortalidade ou a duração da antibioticoterapia nesse cenário (Weiss *et al.*, 2026).

Mais recentemente, métodos moleculares, incluindo ensaios baseados na reação em cadeia da polimerase e plataformas de detecção sindrômica multiplex, que são sistemas automatizados de diagnóstico molecular (PCR) capazes de identificar simultaneamente dezenas de patógenos a partir de uma única amostra, têm sido propostos como recursos diagnósticos promissores, com potencial para reduzir o tempo até a identificação do patógeno e para mitigar o impacto da exposição antimicrobiana prévia sobre o rendimento das culturas, embora ainda demandem validação adicional antes de sua incorporação rotineira (De Rose *et al.*, 2024; Strunk *et al.*, 2024).

Reconhece-se, por fim, que a expressiva proporção de casos rotulados como sepse clínica ou sepse com cultura negativa, situação em que persistem sinais clínicos compatíveis sem confirmação microbiológica, constitui obstáculo adicional à uniformização diagnóstica e à comparabilidade entre estudos, problema diretamente vinculado à ausência de uma definição consensual neonatal (Molloy *et al.*, 2020; Strunk *et al.*, 2024). Nesse contexto, a articulação entre julgamento clínico criterioso, uso racional de biomarcadores e adoção de programas de gerenciamento de antimicrobianos tem sido proposta como a estratégia mais consistente para equilibrar o reconhecimento oportuno da sepse tardia e a contenção da resistência antimicrobiana na assistência neonatal (Raturi; Chandran, 2024; Stocker *et al.*, 2024).

Em março de 2026, a *Surviving Sepsis Campaign*, iniciativa conjunta da *European Society of Intensive Care Medicine* e da *Society of Critical Care Medicine*, publicou a atualização das diretrizes internacionais para o manejo da sepse e do choque séptico em crianças, revisando a versão de 2020. O documento foi elaborado por um painel de 68 especialistas internacionais e contemplou 61 recomendações, das quais cinco classificadas como recomendações fortes, 24 como recomendações condicionais e 10 como declarações de boa prática; em relação à versão anterior, 20 recomendações são inéditas e 13 foram atualizadas à luz de novas evidências (Weiss *et al.*, 2026).

Reveste-se de particular relevância, para o presente referencial, a delimitação de escopo do documento, no qual as recomendações aplicam-se a pacientes com idade gestacional ao nascimento igual ou superior a 37 semanas e até 18 anos de idade, de modo que, embora abranjam o recém-nascido a termo e o pré-termo tardio, excluem explicitamente os prematuros, população de maior incidência e gravidade da sepse neonatal tardia. Tal recorte reforça o argumento, desenvolvido nas seções precedentes, da persistência de uma lacuna normativa específica para o neonato pré-termo (Weiss *et al.*, 2026; Strunk *et al.*, 2024).

No domínio do reconhecimento e da investigação da infecção, a atualização recomenda, com forte intensidade, a implementação de programas institucionais de melhoria de desempenho com procedimentos operacionais padronizados (POP), bem como a mensuração do lactato sanguíneo na avaliação inicial do quadro. Estabelece, ademais, que as hemoculturas devem ser obtidas antes do início da antibioticoterapia sempre que isso não retarde substancialmente sua administração, e considera insuficiente a evidência disponível tanto para a recomendação de rastreamento sistemático rotineiro de sepse quanto para o uso rotineiro de testes moleculares de detecção de patógenos, posicionamento que dialoga diretamente com as limitações diagnósticas discutidas (Weiss *et al.*, 2026; De Rose *et al.*, 2024).

Quanto à terapia antimicrobiana, uma das mudanças conceitualmente mais significativas em relação a 2020 consiste na estratificação do tempo recomendado para o início do tratamento segundo a gravidade da apresentação clínica. Para crianças com suspeita de choque séptico, recomenda-se fortemente o início da terapia o mais breve possível, idealmente em até uma hora do reconhecimento; já para a sepse provável sem choque, sugere-se um curso de investigação rápida e tempo-limitada, com início da antibioticoterapia, caso a suspeita se confirme, idealmente em até três horas. O painel pondera, de modo explícito, que tanto a administração muito precoce, inferior a 30 minutos, quanto a muito tardia se associaram a

maior mortalidade, advertindo contra a prescrição reflexa e desnecessária de antimicrobianos (Weiss *et al.*, 2026).

Essa modulação possui implicação direta para a assistência neonatal, ao buscar equilibrar o reconhecimento oportuno da sepse tardia com a contenção do uso abusivo de antimicrobianos e da consequente pressão seletiva de microrganismos multirresistentes (Raturi; Chandran, 2024; Stocker *et al.*, 2024).

No campo do gerenciamento antimicrobiano, além da recomendação condicional contrária ao uso rotineiro da procalcitonina para desescalonação na vigência de programas efetivos de gestão clínica de antimicrobianos, já referida na seção de diagnóstico, a atualização introduz como recomendação condicional inédita a implementação de consultoria rotineira de infectologia ou microbiologia médica nos casos com infecção de corrente sanguínea documentada, em razão de benefício de mortalidade observado em evidências agrupadas (Weiss *et al.*, 2026).

No tocante ao controle do foco infeccioso, o documento recomenda, com forte intensidade, a remoção de dispositivos de acesso intravascular confirmados como fonte da sepse, após o estabelecimento de acesso vascular alternativo, orientação de elevada pertinência para a sepse neonatal tardia, dada a centralidade dos cateteres venosos centrais como fator de risco descrito na literatura (Weiss *et al.*, 2026; Raturi; Chandran, 2024).

Em relação à reanimação e ao suporte hemodinâmico, a versão de 2026 sugere a utilização de cristaloides balanceados ou tamponados em detrimento da solução salina a 0,9% nas crianças que requerem expansão volêmica, bem como a preferência por cristaloides em relação à albumina na reanimação inicial, com volumes de *bolus* modulados conforme a disponibilidade de cuidados intensivos. Para crianças intubadas após a reanimação, sugere-se um alvo conservador de oxigenação, e o documento mantém posicionamento contrário ao uso rotineiro de corticosteroides quando a estabilidade hemodinâmica é alcançável com fluidos e agentes vasoativos, assim como ao uso rotineiro de imunoglobulina intravenosa e de terapias adjuvantes como vitamina C, tiamina e vitamina D (Weiss *et al.*, 2026).

Por fim, merece destaque a ênfase conferida pela atualização ao seguimento de longo prazo. Reconhecendo que parcela expressiva das crianças que sobrevivem a um episódio de sepse grave evolui com sequelas persistentes, o documento sugere a adoção de medidas individualizadas e precoces de reabilitação durante a fase aguda da doença e considera razoável a avaliação de fatores de risco para morbidade pós-sepse, a educação de familiares e

profissionais quanto aos seus sinais e a vigilância de sequelas após a alta hospitalar (Weiss *et al.*, 2026).

Esse eixo converge com a vulnerabilidade do neurodesenvolvimento descrita na fisiopatologia da sepse neonatal, reforçando que a sobrevida não constitui desfecho suficiente e que o prognóstico funcional a longo prazo deve integrar a avaliação do recém-nascido acometido (Coggins; Glaser, 2022; Strunk *et al.*, 2024). Deve-se observar, contudo, que o conjunto das recomendações se ampara majoritariamente em evidências de baixa ou muito baixa certeza e que persiste a ausência de uma diretriz específica para o neonato pré-termo, o que sustenta a relevância científica de investigações dedicadas à sepse neonatal tardia nessa população (Weiss *et al.*, 2026; Molloy *et al.*, 2020).

1.2 INTELIGÊNCIA ARTIFICIAL E APRENDIZADO DE MÁQUINA EM SAÚDE APLICADA À PREDIÇÃO E AO DIAGNÓSTICO DA SEPSE NEONATAL TARDIA

A inteligência artificial pode ser definida como o campo da ciência da computação que se ocupa da construção de agentes capazes de perceber o ambiente, raciocinar sob incerteza e agir de modo a maximizar a probabilidade de atingir determinados objetivos, executando tarefas que tradicionalmente demandariam inteligência humana (Russell; Norvig, 2021).

Distingue-se, na literatura científica, a inteligência artificial restrita ou aplicada, voltada a tarefas específicas e que corresponde à totalidade das aplicações clínicas atualmente disponíveis, da inteligência artificial geral, de caráter hipotético, que designaria sistemas com capacidade cognitiva ampla e equiparável à humana (Russell; Norvig, 2021; Rajkomar; Dean; Kohane, 2019). No contexto da saúde, o termo é empregado, em sua quase totalidade, no primeiro sentido, referindo-se a sistemas concebidos para apoiar tarefas delimitadas, como a predição de um desfecho clínico específico.

Para situar a inteligência artificial entre as tecnologias empregadas no cuidado, é útil recorrer à classificação proposta por Merhy, que distingue três tipos de tecnologia em saúde: as tecnologias leves, as leve-duras e as duras. As tecnologias leves referem-se às tecnologias das relações, como o acolhimento, o vínculo e a comunicação estabelecidos no encontro entre profissional e paciente; as tecnologias leve-duras correspondem aos saberes estruturados que orientam a prática, como a clínica e a epidemiologia; e as tecnologias duras dizem respeito aos equipamentos, máquinas, instrumentos e estruturas materiais mobilizados na assistência (Merhy, 2002).

Nessa perspectiva, a inteligência artificial e, em particular, os algoritmos de aprendizado de máquina enquadram-se predominantemente como tecnologia dura, por se materializarem em sistemas computacionais, *softwares* e dispositivos de apoio à decisão. Contudo, seu funcionamento é indissociável das tecnologias leve-duras, uma vez que os modelos preditivos incorporam o conhecimento clínico e epidemiológico que estrutura a seleção de variáveis e a interpretação dos resultados. Ademais, sua incorporação ao cuidado somente produz benefício efetivo quando articulada às tecnologias leves, pois o alerta gerado pelo algoritmo depende do julgamento clínico e da relação profissional-paciente para se converter em conduta assistencial adequada (Merhy, 2002).

O aprendizado de máquina constitui o principal subcampo da inteligência artificial aplicado à saúde e refere-se ao conjunto de métodos computacionais que aprendem padrões diretamente a partir dos dados, sem que as regras de decisão sejam explicitamente programadas (Rajkomar; Dean; Kohane, 2019).

Convencionou-se organizar esses métodos em três paradigmas. No aprendizado supervisionado, o modelo é treinado com exemplos rotulados, aprendendo a mapear variáveis de entrada a um desfecho conhecido, situação típica das tarefas de classificação. No aprendizado não supervisionado, não há rótulos predefinidos, e o objetivo é identificar estruturas ou agrupamentos latentes nos dados. No aprendizado por reforço, um agente aprende, por tentativa e erro, a sequência de ações que maximiza uma recompensa, paradigma aplicado a problemas de decisão sequencial, como estratégias terapêuticas (Rajkomar; Dean; Kohane, 2019; Lecun; Bengio; Hinton, 2015).

O aprendizado profundo é um subconjunto do aprendizado de máquina baseado em redes neurais artificiais modelos computacionais inspirados, de forma simplificada, na organização de neurônios biológicos, compostas por múltiplas camadas de processamento. Sua principal característica é a capacidade de aprender automaticamente representações hierárquicas e progressivamente abstratas dos dados, dispensando a engenharia manual de atributos (Lecun; Bengio; Hinton, 2015). Esse paradigma, viabilizado pela disponibilidade de grandes volumes de dados rotulados e pelo aumento da capacidade computacional, foi responsável pelos avanços de desempenho que aproximaram, em tarefas específicas, a acurácia de algoritmos àquela de especialistas humanos (Esteva *et al.*, 2017).

A natureza dos dados utilizados constitui distinção conceitual relevante. Denominam-se dados estruturados aqueles organizados em formato tabular e prontamente processáveis, como sinais vitais, resultados laboratoriais e variáveis demográficas registrados no prontuário

eletrônico; e dados não estruturados aqueles sem organização predefinida, como anotações clínicas em texto livre, traçados de monitorização contínua e imagens (Topol, 2019). Esse aspecto é particularmente pertinente ao ambiente de terapia intensiva, no qual coexistem séries temporais fisiológicas de alta resolução e registros clínicos heterogêneos, configurando o cenário típico de aplicação do aprendizado de máquina em saúde (Beam; Kohane, 2018).

Mais recentemente, consolidou-se o conceito de modelos de fundação, definidos como modelos de grande porte treinados por autossupervisão sobre conjuntos de dados amplos e diversos, capazes de serem adaptados a múltiplas tarefas com pouco ou nenhum dado rotulado específico; os grandes modelos de linguagem constituem seu exemplo mais difundido (Moor *et al.*, 2023). No domínio da saúde, propôs-se o paradigma da inteligência artificial baseado em modelos multimodais aptos a integrar dados de imagem, prontuário, exames laboratoriais e texto clínico, embora sua incorporação à prática ainda enfrente desafios substanciais de validação e segurança (Moor *et al.*, 2023; Husain *et al.*, 2025).

No campo da saúde, esse conjunto de tecnologias passou a exercer impacto em três níveis principais: para os profissionais, sobretudo por meio da interpretação rápida e acurada de imagens; para os sistemas de saúde, pela otimização de fluxos de trabalho e pelo potencial redução de erros assistenciais; e para os pacientes, ao permitir maior protagonismo no manejo de seus próprios dados (Topol, 2019).

Estudos demonstraram desempenho de algoritmos comparável ao de especialistas em tarefas específicas, como a classificação de lesões cutâneas a partir de imagens dermatológicas, consolidando o aprendizado profundo como ferramenta de relevância clínica (Esteva *et al.*, 2017). Paralelamente, autores alertaram que a incorporação do *big data* e do aprendizado de máquina à prática clínica, embora promissora, exige cautela metodológica e avaliação rigorosa antes de sua adoção em larga escala (Beam; Kohane, 2018; Rajkomar; Dean; Kohane, 2019).

Apesar do entusiasmo crescente, a literatura identifica de forma consistente um conjunto de limitações e desafios que condicionam a translação segura desses sistemas para o cuidado. Destacam-se o risco de viés algorítmico e de iniquidade, a limitada generalização dos modelos quando aplicados a populações ou instituições distintas daquelas em que foram desenvolvidos, a baixa interpretação dos modelos complexos, as preocupações relativas à privacidade e à segurança dos dados e a necessidade de marcos regulatórios adequados (Obermeyer *et al.*, 2019; Topol, 2019).

Observou-se uma transição do predomínio de modelos clássicos de aprendizado de máquina para modelos de fundação e modelos multimodais de grande porte, acompanhada do

reconhecimento de que a maturação do campo depende da validação externa, da avaliação prospectiva e da padronização do relato de desempenho dos modelos (Husain *et al.*, 2025).

1.2.1 Inteligência artificial explicável (XAI) e interpretabilidade clínica

Entre as limitações apontadas à adoção da inteligência artificial em saúde, a baixa interpretabilidade dos modelos complexos, frequentemente descrita como o problema da "caixa-preta", ocupa posição de destaque, sobretudo em ambientes de decisão de alto risco como a terapia intensiva. Modelos de elevado desempenho, como os conjuntos de árvores e as redes neurais profundas, produzem predições cuja lógica interna não é diretamente acessível ao raciocínio clínico, o que gera tensão entre acurácia e transparência (Rudin, 2019). Nesse contexto, consolidou-se o campo da inteligência artificial explicável, ou *Explainable Artificial Intelligence* (XAI), que reúne métodos destinados a tornar compreensíveis as razões que levaram um modelo a determinada saída, sem precisar sacrificar seu poder preditivo (Amann *et al.*, 2020).

A explicabilidade não constitui exigência meramente técnica, mas condição clínica, ética e regulatória para a incorporação responsável desses sistemas ao cuidado, na medida em que profissionais tendem a confiar e a aderir a um alerta automatizado apenas quando conseguem compreender quais variáveis o motivaram (Amann *et al.*, 2020).

Entre as técnicas de explicabilidade, destacam-se os valores SHAP (*SHapley Additive exPlanations*), fundamentados na teoria dos jogos, que atribuem a cada variável de entrada uma contribuição quantitativa e sinalizada para a predição individual, permitindo tanto a interpretação local de cada alerta quanto a análise global da importância dos atributos do modelo (Lundberg; Lee, 2017). A adoção dessas ferramentas alinha o desenvolvimento de modelos preditivos à demanda por transparência e confiança dos sistemas de apoio à decisão clínica.

Um desafio adicional recorrente na aplicação do aprendizado de máquina a dados clínicos reside no desbalanceamento de classes. Em problemas como a predição da sepse neonatal tardia, os recém-nascidos que efetivamente desenvolvem o desfecho constituem a minoria da população estudada, uma vez que a incidência do agravo, ainda que clinicamente relevante, situa-se substancialmente abaixo dos casos sem infecção. Bancos de dados assistenciais tendem, portanto, a apresentar acentuada assimetria entre a classe de interesse (evento raro) e a classe majoritária (ausência do evento). Modelos de aprendizado de máquina

treinados sobre dados desbalanceados tendem a privilegiar a classe majoritária, alcançando acurácia global elevada às custas de baixa sensibilidade para a classe minoritária, justamente aquela de maior relevância clínica (Chawla *et al.*, 2002).

Esse viés algorítmico decorrente da assimetria de classes tem implicações metodológicas diretas. A literatura recomenda, por um lado, a adoção de métricas de desempenho robustas ao desbalanceamento, como o F1-*score*, que integra sensibilidade e valor preditivo positivo e é menos suscetível à distorção provocada pela predominância da classe negativa do que a acurácia isolada; e, por outro, o emprego de técnicas de reamostragem que reequilibram a distribuição das classes no conjunto de treinamento, com destaque para a sobreamostragem sintética da classe minoritária, exemplificada pelo algoritmo SMOTE (*Synthetic Minority Over-sampling Technique*), que gera exemplos artificiais plausíveis a partir dos casos observados (Chawla *et al.*, 2002).

A atenção a essas estratégias mostra-se especialmente pertinente aos estudos de predição de sepse, nos quais a heterogeneidade metodológica e o risco de viés já foram apontados como fragilidades frequentes (Nikravangolsefid *et al.*, 2024).

1.2.2 Inteligência artificial na predição de sepse em UTI

A sepse reúne características que a tornam um problema particularmente adequado à abordagem por aprendizado de máquina: trata-se de condição tempo-dependente, de manifestações clínicas inespecíficas, cujo desfecho é fortemente influenciado pela precocidade do tratamento e cujo cuidado, em unidade de terapia intensiva, gera grande volume de dados clínicos, laboratoriais e de monitorização contínua passíveis de análise computacional (Fleuren *et al.*, 2020).

Nesse cenário, modelos preditivos já foram desenvolvidos com o objetivo de antecipar o reconhecimento da síndrome em relação à deterioração clínica evidente. Um marco inicial foi o escore de alerta precoce em tempo real para choque séptico, que demonstrou capacidade de antecipar o evento horas antes de sua instalação a partir de dados fisiológicos e laboratoriais de rotina (Henry *et al.*, 2015).

Além da predição diagnóstica, abordagens de aprendizado por reforço foram propostas para a otimização terapêutica. Um modelo denominado “Clínico de Inteligência Artificial” extraiu conhecimento implícito de extenso conjunto de dados de pacientes para sugerir estratégias de administração de fluidos e de agentes vasoativos no choque séptico, com a

observação de que a aderência às decisões sugeridas pelo modelo se associou, em coorte de validação, a menor mortalidade (Komorowski *et al.*, 2018). Em etapa subsequente de translação clínica, um sistema de alerta precoce baseado em aprendizado de máquina, avaliado de forma prospectiva e multicêntrica, associou-se à redução do tempo até a administração de antimicrobianos e à melhora de desfechos quando os profissionais interagiam com seus alertas, ilustrando o potencial dessas ferramentas quando integradas ao processo de cuidado (Adams *et al.*, 2022).

Em contrapartida, a experiência acumulada também evidenciou os riscos da incorporação acrítica desses sistemas. A validação externa de um modelo proprietário de predição de sepse amplamente implementado em centenas de hospitais revelou discriminação e calibração insatisfatórias, com baixo valor preditivo positivo e elevada carga de alarmes, demonstrando que o bom desempenho relatado no desenvolvimento não se sustentou em contexto independente (Wong *et al.*, 2021).

Revisões sistemáticas com meta-análise confirmaram a heterogeneidade metodológica e o risco de viés que permeiam grande parte dos estudos da área, ressaltando a fragilidade da evidência disponível (Nikravangolsefid *et al.*, 2024). Tais achados motivaram posicionamentos de cautela quanto à detecção precoce de sepse por inteligência artificial, com ênfase nos fenômenos de fadiga de alarmes e de equívoco relacionado aos processos de cuidado (Schinkel; Van Der Poll; Wiersinga, 2023). Em conjunto, essas evidências sustentam que a validação externa, a calibração, a avaliação prospectiva e a integração criteriosa ao fluxo de trabalho são condições indispensáveis para a utilidade clínica desses modelos (Wong *et al.*, 2021; Adams *et al.*, 2022).

A unidade de terapia intensiva neonatal constitui ambiente especialmente propício à aplicação da inteligência artificial, em razão da monitorização fisiológica contínua e de alta resolução, da geração de dados multidimensionais e das internações prolongadas de uma população reconhecidamente vulnerável (Sullivan; Kausch; Fairchild, 2023; Husain *et al.*, 2025).

Evidências demonstram que alterações sutis nas características da frequência cardíaca, redução da variabilidade e desacelerações transitórias, precedem as manifestações clínicas da sepse neonatal, fundamentando o desenvolvimento de índices de monitorização contínua. Um ensaio clínico randomizado que avaliou a exibição contínua do índice de características da frequência cardíaca em 3.003 recém-nascidos de muito baixo peso, distribuídos em nove unidades neonatais, constitui marco da área, com a visualização do índice à beira do leito

associou-se a redução relativa da mortalidade de aproximadamente 22%, com benefício concentrado no entorno dos episódios sépticos (Moorman *et al.*, 2011). Esse achado consolidou a hipótese de que a análise computacional de sinais fisiológicos pode antecipar o reconhecimento da sepse e impactar desfechos clínicos relevantes.

Avanços subsequentes ampliaram a abordagem para modelos que integram múltiplos sinais de monitorização contínua. Sistemas de apoio à decisão clínica baseados em aprendizado de máquina foram desenvolvidos para a predição horária do risco de sepse tardia e de enterocolite necrosante em prematuros, demonstrando ganho de antecipação clínica relevante em relação ao reconhecimento convencional (Meeus *et al.*, 2024). Revisões sintetizaram tanto as aplicações específicas à predição da sepse neonatal, enfatizando a complementaridade entre a inteligência computacional e a inteligência e a experiência humanas na decisão de quando tratar (Sullivan; Kausch; Fairchild, 2023), quanto o panorama mais amplo da predição de desfechos clínicos e de tempo de internação na unidade neonatal, apontando oportunidades e desafios para a implementação prática (Tudor *et al.*, 2025).

Não obstante o potencial descrito, a aplicação da inteligência artificial à neonatologia enfrenta desafios particulares. Destacam-se o tamanho frequentemente reduzido das amostras, a heterogeneidade associada à idade gestacional, a dificuldade de definição do desfecho de referência, questão diretamente relacionada à ausência de uma definição consensual de sepse neonatal, a limitada generalização entre diferentes unidades e as considerações éticas inerentes ao cuidado de uma população vulnerável (Husain *et al.*, 2025; Sullivan; Kausch; Fairchild, 2023).

Diante desse cenário, estudos propuseram, de forma colaborativa, a padronização do relato de desempenho dos modelos em neonatologia, como medida necessária para assegurar a comparabilidade, a reprodutibilidade e a translação responsável dessas tecnologias ao leito (Husain *et al.*, 2025). Assim, a predição da sepse neonatal tardia por inteligência artificial configura-se como alternativa promissora, condicionada, contudo, a validação rigorosa, avaliação prospectiva e integração criteriosa à prática clínica (Sullivan; Kausch; Fairchild, 2023; Tudor *et al.*, 2025).

A qualidade preditiva de qualquer modelo de aprendizado de máquina aplicado à terapia intensiva neonatal é indissociável da qualidade dos dados que o alimentam, e, nesse ponto, a equipe de enfermagem assume papel crucial. É a enfermagem que realiza, de forma contínua e à beira do leito, o registro sistemático dos sinais vitais, da oximetria de pulso, do balanço hídrico, das observações clínicas e das intercorrências que compõem a maior parte das variáveis

dinâmicas do prontuário eletrônico, especialmente no recém-nascido criticamente enfermo, cuja monitorização é ininterrupta. Diferentemente de dados laboratoriais pontuais ou de registros médicos episódicos, as informações produzidas pela enfermagem caracterizam-se pela alta frequência temporal e pela proximidade com a deterioração fisiológica, constituindo a principal fonte de séries temporais utilizadas na predição precoce da sepse neonatal tardia (Sullivan; Kausch; Fairchild, 2023).

Decorre dessa centralidade que a acurácia, a completude e a tempestividade do registro de enfermagem condicionam diretamente o desempenho do modelo. Registros ausentes, atrasados ou inconsistentes introduzem ruído e vieses sistemáticos que podem comprometer o aprendizado do algoritmo, uma vez que o modelo tende a reproduzir os padrões e as limitações inerentes ao próprio processo assistencial que gerou os dados (Agniel; Kohane; Weber, 2018). Assim, mais do que a equipe médica, é a equipe de enfermagem que se configura como a principal responsável pela alimentação contínua do prontuário eletrônico e, por conseguinte, pela matéria-prima informacional sobre a qual se constroem os modelos preditivos. Reconhecer o registro de enfermagem como insumo crítico de qualidade dos dados reforça a necessidade de padronização, capacitação e valorização dessa prática como etapa estruturante e não meramente acessória do desenvolvimento de sistemas de inteligência artificial em saúde.

1.2.3 Escores clínicos aplicados à avaliação do recém-nascido: adaptação neonatal da Escala de Coma de Glasgow, NEWS2, qSOFA e nSOFA

A incorporação de escores clínicos estruturados a modelos preditivos de sepse decorre da necessidade de traduzir, em variáveis objetivas e reprodutíveis, a deterioração fisiológica que precede o reconhecimento clínico da infecção. Tais escores sintetizam sinais vitais, nível de consciência e marcadores de disfunção orgânica em pontuações padronizadas, favorecendo tanto a vigilância à beira do leito quanto a estruturação de variáveis preditoras para algoritmos de aprendizado de máquina (Sullivan; Kausch; Fairchild, 2023; Husain *et al.*, 2025). No contexto da sepse neonatal, quatro instrumentos revestem-se de particular interesse: a adaptação neonatal da Escala de Coma de Glasgow, o *National Early Warning Score 2* (NEWS2), o *Quick Sequential Organ Failure Assessment* (qSOFA) e o *Neonatal Sequential Organ Failure Assessment* (nSOFA).

A Escala de Coma de Glasgow, descrita originalmente por Teasdale e Jennett em 1974, avalia o nível de consciência a partir de três domínios, de abertura ocular, resposta verbal e

resposta motora, e consolidou-se como um dos instrumentos mais utilizados e citados da neurologia clínica (Teasdale; Jennett, 1974). Sua aplicação ao recém-nascido e ao lactente, contudo, esbarra na impossibilidade de avaliar a resposta verbal e a compreensão de comandos motores nos moldes do adulto, o que motivou o desenvolvimento de adaptações pediátricas e neonatais.

A Escala de Coma de Glasgow pediátrica modificada, derivada dos trabalhos de James e Trauner e posteriormente sistematizada por Tatman *et al.* e pela *British Paediatric Neurology Association*, substitui a resposta verbal por parâmetros observáveis apropriados à idade, como o padrão de choro, a interação e a resposta a estímulos, adequando a avaliação neurológica às capacidades do neonato (Tatman *et al.*, 1997; British Paediatric Neurology Association, 2001). Essa adaptação mostra-se pertinente à sepse neonatal na medida em que a alteração do estado de alerta, a letargia e a irritabilidade figuram entre as manifestações iniciais mais frequentes, ainda que inespecíficas, da infecção sistêmica no período neonatal (Shane; Sánchez; Stoll, 2017; Procianoy; Silveira, 2020).

O *National Early Warning Score 2* (NEWS2), atualização do NEWS aprovada pelo *National Health Service* do Reino Unido, agrega seis parâmetros fisiológicos de fácil obtenção, como a frequência respiratória, a saturação periférica de oxigênio, a pressão arterial sistólica, a frequência cardíaca, a temperatura e o nível de consciência, com o objetivo de detectar precocemente a deterioração clínica e desencadear a escalada do cuidado (Durr *et al.*, 2022).

Estudos recentes em populações com sepse têm demonstrado que o NEWS2 apresenta, de modo geral, maior sensibilidade e melhor discriminação de desfechos que o qSOFA na predição de admissão em terapia intensiva e de mortalidade, embora com menor especificidade, o que sustenta seu emprego preferencial como ferramenta de rastreamento (Durr *et al.*, 2022; Devia-Jaramillo *et al.*, 2025). Cumpre ressaltar, entretanto, que os pontos de corte e as faixas de normalidade dos sinais vitais do NEWS2 foram concebidos para adultos, de modo que sua aplicação à neonatologia exige a adoção de referências fisiológicas ajustadas à idade gestacional e pós-natal, princípio que fundamenta o desenvolvimento de sistemas de alerta precoce especificamente neonatais (Chaithaweesup *et al.*, 2026).

O *Quick Sequential Organ Failure Assessment* (qSOFA), proposto a partir das definições do Terceiro Consenso Internacional para Sepse e Choque Séptico (Sepsis-3), constitui instrumento simplificado de rastreamento à beira do leito, composto por três critérios, como a frequência respiratória igual ou superior a 22 incursões por minuto, a alteração do estado mental e a pressão arterial sistólica igual ou inferior a 100mmHg, voltado à identificação

de pacientes com infecção sob maior risco de desfechos desfavoráveis (Singer *et al.*, 2016). Apesar de sua praticidade, o qSOFA tem sido criticado por apresentar baixa sensibilidade como ferramenta de triagem isolada, particularmente fora da terapia intensiva, e, à semelhança do NEWS2, não foi validado para a população neonatal, o que restringe sua aplicação direta ao recém-nascido e reforça a necessidade de instrumentos organizados segundo a fisiologia neonatal (Durr *et al.*, 2022; Devia-Jaramillo *et al.*, 2025).

Diante dessas limitações, o *Neonatal Sequential Organ Failure Assessment* (nSOFA) foi desenvolvido por Wynn e Polin como uma operacionalização da disfunção orgânica específica para o neonato, contemplando os componentes respiratório, cardiovascular e hematológico, e demonstrou capacidade de predizer a mortalidade associada à sepse tardia em recém-nascidos prematuros de muito baixo peso (Wynn; Polin, 2020). Evidências recentes ampliaram e consolidaram sua utilidade. Em coorte retrospectiva de larga escala, o nSOFA apresentou boa a excelente discriminação para a mortalidade relacionada à infecção de início tardio, com desempenho crescente quando avaliado seis horas após o início da investigação, sustentando sua proposição como fundamento para uma definição consensual de sepse neonatal (Al Gharaibeh *et al.*, 2025).

Estudos adicionais evidenciaram, ainda, que o nSOFA aferido nas primeiras horas após a suspeita de sepse associa-se não apenas à mortalidade, mas também a desfechos respiratórios adversos e a morbidades da prematuridade, como a displasia broncopulmonar e a retinopatia da prematuridade (Poggi *et al.*, 2025; Kurul *et al.*, 2024; Yaman *et al.*, 2025).

Do ponto de vista metodológico, a natureza objetiva e automatizável desses escores, sobretudo do nSOFA, cujos componentes podem ser extraídos diretamente do prontuário eletrônico, torna-os candidatos privilegiados a variáveis preditoras em modelos de aprendizado de máquina, seja como atributos isolados, seja de forma composta (Wynn; Polin, 2020; Al Gharaibeh *et al.*, 2025). A incorporação desses instrumentos possui a capacidade de sintetizar, em variáveis padronizadas e clinicamente interpretáveis, a deterioração fisiológica e a disfunção orgânica do recém-nascido (Sullivan; Kausch; Fairchild, 2023; Husain *et al.*, 2025).

Os escores clínicos estruturados apresentados, ao sintetizarem a deterioração fisiológica e a disfunção orgânica do recém-nascido em variáveis padronizadas e reprodutíveis, constituem a matéria-prima informacional a ser processada computacionalmente. Tais variáveis, uma vez estruturadas, alimentam o processo de extração de padrões que na etapa de mineração de dados ao converter tais indicadores clínicos em conhecimento preditivo. Estabelece-se, assim, a ponte

entre a avaliação clínica beira-leito e o percurso metodológico da Descoberta de Conhecimento em Bases de Dados (KDD).

1.3 O PROCESSO DE DESCOBERTA DE CONHECIMENTO EM BASES DE DADOS (KDD)

A extração de conhecimento útil a partir de grandes volumes de dados clínicos não decorre da simples aplicação de um algoritmo, mas de um processo estruturado e iterativo, formalizado na literatura como *Knowledge Discovery in Databases* (KDD), ou Descoberta de Conhecimento em Bases de Dados. O conceito foi consolidado por Fayyad, Piatetsky-Shapiro e Smyth (1996), que definiram o KDD como o processo não trivial de identificação de padrões válidos, novos, potencialmente úteis e, sobretudo, compreensíveis a partir dos dados (Fayyad; Piatetsky-Shapiro; Smyth, 1996). Nessa perspectiva, a mineração de dados constitui apenas uma das etapas do processo, e não a sua totalidade, distinção que permanece central na literatura sobre o tema (El-Sappagh *et al.*, 2013; Sharda; Delen; Turban, 2021).

O KDD organiza-se como uma sequência de operações sobre os dados que os conduz, de forma incremental, do estado bruto ao conhecimento acionável, admitindo retornos a etapas anteriores sempre que necessário (Fayyad; Piatetsky-Shapiro; Smyth, 1996). Sua natureza interdisciplinar, situada na interseção entre a inteligência artificial, a estatística, os bancos de dados e o aprendizado de máquina, torna-o particularmente adequado ao domínio da saúde, no qual coexistem dados heterogêneos, elevada dimensionalidade e a necessidade de interpretação clínica dos resultados (El-Sappagh *et al.*, 2013; Nwankwo *et al.*, 2023).

Classicamente, o processo é descrito em cinco etapas, sintetizadas no Quadro 1 (Fayyad; Piatetsky-Shapiro; Smyth, 1996).

Quadro 1 – Etapas do processo de Descoberta de Conhecimento em Bases de Dados (KDD), Teresina, Piauí, Brasil. 2026.

ETAPAS DO PROCESSO KDD	
Etapa	**Descrição**
Seleção	Etapa inicial, na qual se define o conjunto de dados-alvo, selecionando-se as bases, os registros e as variáveis pertinentes ao problema investigado, a partir da compreensão do domínio de aplicação e dos objetivos da descoberta.
Pré-processamento	Fase de limpeza e preparação dos dados selecionados, que compreende o tratamento de valores ausentes, a remoção de ruídos e inconsistências, a identificação de dados discrepantes e a integração de fontes heterogêneas, produzindo dados consistentes para as etapas subsequentes.
Transformação	Conversão dos dados pré-processados em formatos adequados à mineração, incluindo a redução de dimensionalidade, a normalização, a codificação de variáveis e a construção ou seleção de atributos relevantes.
	Etapa central e mais reconhecida do processo, na qual se aplicam algoritmos de

Mineração de dados	aprendizado de máquina e de reconhecimento de padrões, como tarefas de classificação, regressão e agrupamento, aos dados transformados, com vistas à extração dos padrões de interesse.
Interpretação e avaliação	Etapa final, em que os padrões extraídos são avaliados quanto à sua validade, novidade e utilidade, interpretados à luz do conhecimento do domínio e representados de modo compreensível, consolidando-se como conhecimento.

Fonte: elaborado pela autora (2026), com base em Fayyad, Piatetsky-Shapiro e Smyth (1996), El-Sappagh *et al.* (2013) e Sharda, Delen e Turban (2021).

Aplicado à saúde, o KDD tem sido empregado na mineração de prontuários eletrônicos para o apoio à decisão clínica, a predição de desfechos e a estratificação de risco, contribuindo para a transformação de dados assistenciais dispersos em conhecimento útil à prática (Nwankwo *et al.*, 2023).

3 METODOLOGIA

3.1 TIPO DE ESTUDO

Trata-se de um estudo de coorte retrospectivo fundamentado em técnicas de aprendizado de máquina ou, do inglês, *Machine Learning* (ML), especialmente por meio de tarefas de classificação e regressão. Estudos retrospectivos que utilizam algoritmos de ML aplicados a dados históricos provenientes de prontuários eletrônicos em saúde permitem a identificação de padrões clínicos complexos, a predição de desfechos assistenciais e a classificação de fenótipos com maior precisão analítica (Agniel; Kohane; Weber, 2018; Mandair et al., 2020).

Os estudos de coorte retrospectivos constituem um delineamento observacional analítico amplamente utilizado na pesquisa clínica e epidemiológica para investigar associações entre exposições prévias e desfechos já ocorridos, a partir da análise de dados históricos previamente registrados. Nesse tipo de estudo, os pesquisadores identificam uma população ou coorte com características em comum e, com base em registros passados, como

prontuários eletrônicos, bancos de dados hospitalares, sistemas de vigilância ou registros administrativos, reconstroem a trajetória dos indivíduos para avaliar a ocorrência de determinados eventos ou agravos em saúde (Snowden; Klebanoff, 2022).

A integração entre inteligência artificial e registros eletrônicos em saúde representa uma estratégia essencial para a produção de evidências do mundo real (real-world evidence), possibilitando a transformação de dados previamente armazenados em modelos preditivos capazes de subsidiar a tomada de decisão clínica e aprimorar a qualidade do cuidado em saúde (Mukherjee et al., 2023; Lambert et al., 2024).

3.2 LOCAL E PARTICIPANTES DO ESTUDO

O estudo será realizado na Unidade de Terapia Intensiva Neonatal (UTIN) de uma maternidade pública de referência de alta complexidade, localizada na capital do Piauí, Teresina. A unidade dispõe de 30 leitos de UTIN e presta assistência a recém-nascidos prematuros e a termo com diversas condições clínicas e cirúrgicas, sendo referência regional para cuidados neonatais críticos. A instituição mantém prontuário eletrônico com registro estruturado de dados clínicos, laboratoriais e de sinais vitais.

Serão incluídos dados retrospectivos referentes a um período mínimo de três anos (2023-2025), com coleta junto aos prontuários eletrônicos e ao sistema de informação hospitalar. Os participantes do estudo serão constituídos por recém-nascidos, internados na UTIN com tempo de internação superior a 72 horas. Estima-se uma amostra mínima de 700 pacientes, considerando a incidência esperada de sepse tardia entre 15% e 25% nessa população, podendo aumentar conforme o avanço do estudo ou necessidade, para o treinamento adequado dos modelos preditivos com validação cruzada. Serão considerados, para a coleta, dados dos últimos três anos, obtidos a partir dos prontuários dos pacientes.

3.3 CRITÉRIOS DE INCLUSÃO E EXCLUSÃO

Os critérios de inclusão serão: recém-nascidos internados na UTIN por período superior a 72 horas; idade gestacional igual ou superior a 22 semanas; dados registrados em prontuário eletrônico; ausência de diagnóstico de sepse precoce nos primeiros três dias de vida.

Os critérios de exclusão serão: recém-nascidos com malformações congênitas graves ou síndromes genéticas que comprometam a resposta imune; óbito nas primeiras 72 horas de

internação; dados incompletos para as variáveis preditoras essenciais; transferência para outra unidade antes de 72 horas de internação. Prontuários que apresentam dados incompletos para qualquer uma das variáveis utilizadas no estudo serão excluídos das análises.

A adoção da idade gestacional igual ou superior a 22 semanas como critério de inclusão fundamenta-se no conceito de viabilidade do recém-nascido preconizado pelo Ministério da Saúde. No Manual de Vigilância do Óbito Infantil e Fetal, o Ministério da Saúde estabelece que a mortalidade perinatal deve considerar os óbitos fetais e neonatais precoces com peso ao nascer a partir de 500 gramas e/ou 22 semanas de idade gestacional, adotando esse ponto como limite de viabilidade e como referência mais apropriada para a análise da assistência obstétrica e neonatal (Brasil, 2009). Esse marco é corroborado pela literatura nacional sobre o limite de viabilidade no cuidado intensivo neonatal, que documenta o deslocamento progressivo dessa fronteira para idades gestacionais cada vez mais precoces em decorrência dos avanços da terapia intensiva neonatal, situando-a atualmente em torno de 22 a 23 semanas (Brasil, 2011).

Ao estabelecer o limiar de 22 semanas, o presente estudo assegura a inclusão de recém-nascidos considerados viáveis segundo os parâmetros oficiais brasileiros, contemplando justamente a população de prematuros extremos que apresenta maior risco de sepse neonatal tardia e maior potencial de benefício com a predição precoce do desfecho (Brasil, 2009).

3.4 VARIÁVEL-ALVO

A variável-alvo (desfecho) será a ocorrência de sepse neonatal tardia, avaliada utilizando-se a evolução médica, a partir da definição da Classificação Internacional de Doenças (CID-10) para os termos A41.9 (septicemia não especificada) e P36 (septicemia bacteriana do recém-nascido). A variável-alvo será composta de uma variável dicotômica, com valores sim ou não para sepse tardia durante o tempo de internação.

3.5 VARIÁVEIS PREDITORAS

A etapa de mineração das variáveis preditoras será restrita aos dados disponíveis na data da última evolução do paciente no prontuário eletrônico. As variáveis serão definidas com base na literatura científica nacional e internacional e adaptadas ao contexto da UTI neonatal, e serão organizadas em cinco categorias: variáveis demográficas e do parto; variáveis clínicas e de internação; variáveis laboratoriais; variáveis microbiológicas; e escores clínicos.

3.5.1 Variáveis demográficas e do parto e variáveis clínicas e de internação

O quadro 2 apresenta as variáveis demográficas e do parto e as variáveis clínicas e de internação a serem coletadas.

Quadro 2 – Variáveis demográficas e do parto e as variáveis clínicas e de internação. Teresina, Piauí, Brasil. 2026.

VARIÁVEIS DEMOGRÁFICAS E DO PARTO E AS VARIÁVEIS CLÍNICAS E DE INTERNAÇÃO	
Variáveis demográficas e do parto	Sexo do recém-nascido (masculino/feminino).
	Idade gestacional ao nascer (em semanas completas).
	Peso ao nascer (gramas).
	Índice de Ápgar no 1º e 5º minuto.
	Tipo de parto (vaginal ou cesariana).
	Idade materna.
	Raça ou cor do recém-nascido e da mãe.
	Número de gestações anteriores.
	Intercorrências gestacionais (infecção do trato urinário materna, rotura prematura de membranas ovulares, corioamnionite, pré-eclâmpsia).
	Uso de antibiótico materno intraparto.
Variáveis clínicas e de internação	Quantidade total de tempo permanecente na UTIN (dias).
	Uso de ventilação mecânica invasiva (sim/não e número de dias).
	Uso de cateter venoso central (sim/não e dias de permanência).
	Uso de cateter umbilical (sim/não).
	Nutrição parenteral total (sim/não e número de dias).
	Uso de antibióticos previamente à sepse tardia (sim/não e classes utilizadas). (*Continua)*
	Histórias sugestivas de infecção (sim/não).
	Critérios de disfunção orgânica (sim/não).
	Diagnóstico de enterocolite necrosante (sim/não).
	Diagnóstico de hemorragia intraventricular (graus I-IV).
	Temperatura corporal (valores mínimo, máximo e médio durante a internação).
	Frequência cardíaca.
	Frequência respiratória.
	Valores de oximetria de pulso/saturação de oxigênio (SpO2).
	Pressão arterial sistólica.
	Pressão arterial diastólica.
	Uso de vasopressor (sim/não e droga utilizada).
	Uso de surfactante exógeno (sim/não).
	Episódios de apneia e bradicardia (número de episódios por 24 horas).
	Intervalo de tempo para diagnóstico de sepse (dias desde a internação). (*Conclusão)*

Fonte: elaborado pela autora (2026).

3.5.2 Variáveis Laboratoriais

As variáveis laboratoriais serão coletadas retrospectivamente, tomando-se como referência temporal o momento da suspeita clínica de sepse tardia, isto é, o instante em que a equipe assistencial, diante de sinais clínicos compatíveis, instituiu a investigação diagnóstica e

solicitou a coleta de hemocultura. Adota-se esse marco por ser o ponto de decisão clínica em que os exames complementares são efetivamente requisitados na prática assistencial, estratégia consonante com estudos de predição de sepse neonatal que definem as variáveis de entrada a partir dos dados disponíveis no momento da suspeita (*sepsis suspicion*), evitando a incorporação de informações posteriores que caracterizariam vazamento temporal de dados e comprometeriam a validade do modelo preditivo (Kainth *et al.*, 2025; Meeus *et al.*, 2024).

Para os exames com determinações seriadas, serão considerados os valores obtidos na janela temporal em torno da avaliação de sepse, contemplando a última medida disponível previamente à suspeita e as primeiras medidas obtidas até 24 horas após esse marco, de modo a capturar a evolução laboratorial precoce do quadro. Essa definição fundamenta-se na literatura sobre escores de disfunção orgânica neonatal, que demonstra ganho de discriminação diagnóstica e prognóstica quando os parâmetros são reavaliados nas primeiras horas após o início da investigação, notadamente entre a avaliação inicial (T0) e as seis horas subsequentes (T6) ao redor da coleta da hemocultura (Al Gharaibeh *et al.*, 2025; Kurul *et al.*, 2024). Quando não houver determinação disponível dentro da janela estabelecida, o dado será tratado como ausente e submetido aos procedimentos de imputação descritos na etapa de pré-processamento. Também serão coletadas as variáveis microbiológicas e os escores clínicos (Quadro 3).

Quadro 3 – Variáveis laboratoriais, variáveis microbiológicas e os escores clínicos. Teresina, Piauí, Brasil. 2026.

VARIÁVEIS	
Variáveis laboratoriais	Contagem de glóbulos brancos (leucócitos totais).
	Neutrófilos segmentados e bastões.
	Relação Imaturos/Totais (IT) - índice de Rodwell.
	Valores de plaquetas.
	Proteína C Reativa (PCR) - valor quantitativo.
	Procalcitonina (PCT) - quando disponível.
	Valores de glicemia.
	Valores de creatinina sérica.
	Valores de bilirrubina total e frações.
	Valores de pH do sangue (arterial ou venoso).
	Valores de lactato sérico.
	Hemoglobina e hematócrito.
	Sódio, potássio, cálcio ionizado.
	TGO/TGP (aminotransferases).
	Relação Neutrófilos/Linfócitos (marcador inflamatório).
Variáveis microbiológicas	Resultado da hemocultura (positiva/negativa e o agente isolado).
	Perfil de sensibilidade antimicrobiana.
	Histórico de infecções relacionadas à assistência à saúde.
	Colonização por *Staphylococcus* coagulase-negativo ou *Klebsiella sp*.
Escores clínicos	Escala de Coma de Glasgow neonatal adaptada.
	NEWS2 (National Early Warning Score).
	qSOFA Score (Quick Sequencial Organ Failure Assessment).

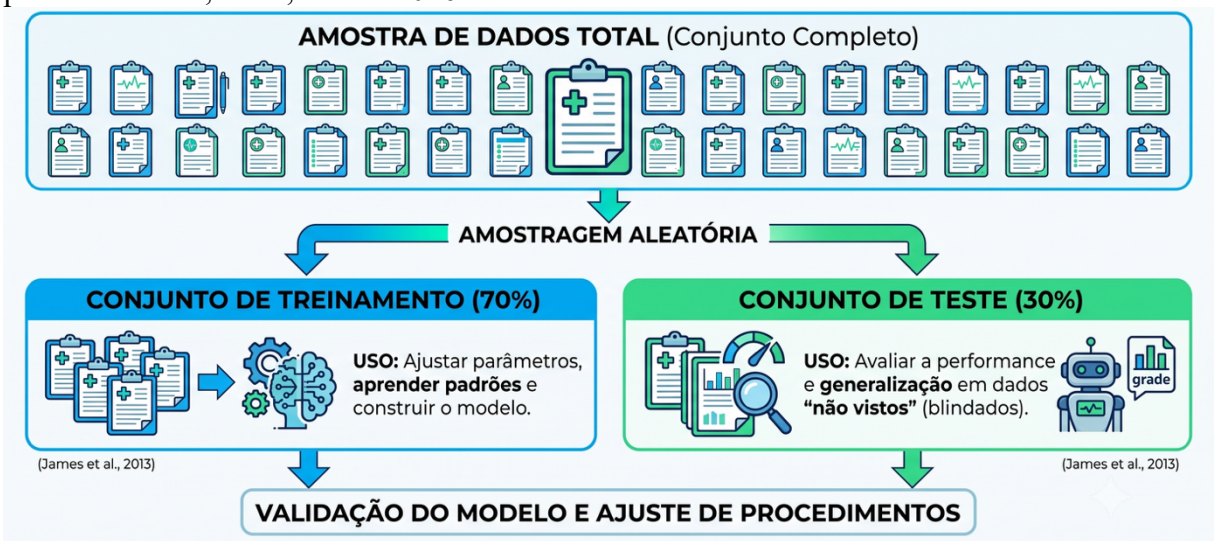
Fonte: elaborado pela autora (2026).

3.6 TREINAMENTO PARA A COLETA DE DADOS E TESTE PILOTO

Previamente ao início da coleta definitiva, será conduzido um processo de capacitação da pesquisadora, com o objetivo de padronizar os procedimentos de identificação, registro e categorização das variáveis nos prontuários eletrônicos. O treinamento abrangerá a apresentação do instrumento de coleta, a definição operacional de cada variável demográfica, clínica, laboratorial, microbiológica e de escore clínico, os critérios diagnósticos de sepse neonatal tardia (CID-10 A41.9 e P36) e as normas de sigilo e anonimização dos dados, em conformidade com a Lei Geral de Proteção de Dados Pessoais (Lei nº 13.709/2018).

Após a etapa de capacitação, será realizado um teste piloto com uma amostra reduzida de prontuários, correspondente a aproximadamente 70% para treinamento do modelo e 30% para teste do total estimado, selecionada de forma aleatória e não incluída na análise final. A escolha pela proporção de divisão de dados de 70/30% (*holdout method*) é uma prática amplamente consolidada e recomendada na literatura de aprendizado de máquina e modelagem preditiva (James *et al.,* 2013; Kuhn; Johnson, 2013). Essa partição garante que a maior fração dos dados (70%) seja destinada ao ajuste dos parâmetros do algoritmo para a identificação de padrões robustos, enquanto uma fração menor e independente (30%) é rigorosamente blindada para estimar o desempenho de generalização e a acurácia do modelo em dados inéditos, mitigando o risco de sobreajuste (*overfitting*) (James *et al.*, 2013) (Figura 1).

Figura 1 – Fluxograma de partição da amostra pelo Método Holdout (70/30%) para o teste piloto. Teresina, Piauí, Brasil. 2026.



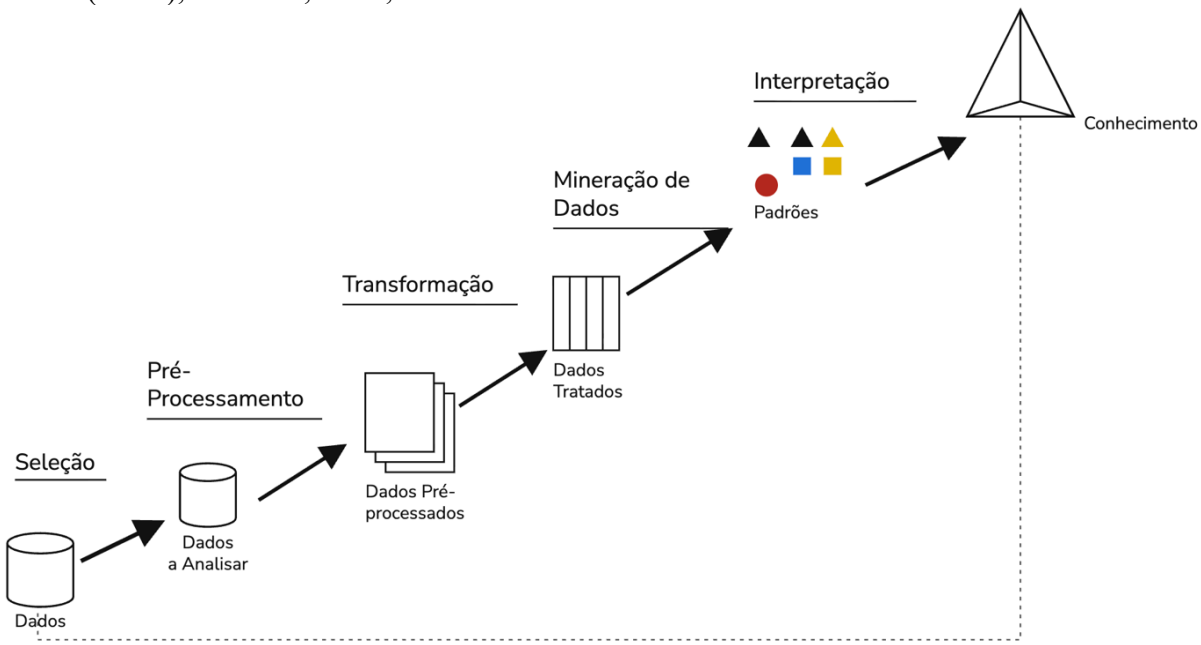
Fonte: elaborada pela autora (2026), adaptado de James *et al*. (2013).

O teste piloto tem por finalidade avaliar a clareza e a adequação do instrumento de coleta, verificar a disponibilidade e a consistência dos registros nas fontes de dados, estimar o tempo médio de preenchimento por prontuário e identificar eventuais ambiguidades ou lacunas nas definições operacionais das variáveis. As divergências identificadas serão analisadas, e o instrumento de coleta será revisado e ajustado conforme os achados. Somente após a validação do instrumento e a padronização dos procedimentos terá início a coleta definitiva dos dados.

3.7 COLETA DE DADOS E PROCESSO KDD

A coleta de dados será realizada nos prontuários eletrônicos da UTIN da instituição participante, adotando-se estratégia híbrida que combina a extração automatizada dos registros a partir do sistema de prontuário eletrônico com etapas subsequentes de auditoria e validação manual. O processo seguirá as cinco etapas do KDD de seleção dos dados, pré-processamento, transformação e normalização, mineração de dados e avaliação e pós-processamento (Figura 2).

Figura 2 – Fluxograma das etapas do processo de Descoberta de Conhecimento em Bases de Dados (KDD), Teresina, Piauí, Brasil. 2026.



Fonte: elaborada pela autora (2026), adaptada de Fayyad, Piatetsky-Shapiro e Smyth (1996).

O prontuário eletrônico utilizado pela Nova Maternidade Dona Evangelina Rosa (NMDER) é o sistema SOUL MV, plataforma de gestão hospitalar desenvolvida pela MV Sistemas e amplamente empregada em instituições de saúde brasileiras. A extração dos dados será conduzida mediante integração programática com o sistema SOUL MV, por meio de

chaves de interface de programação de aplicações (*Application Programming Interface Keys* - API *Keys*). Esse recurso possibilita a consulta estruturada às tabelas do prontuário eletrônico e a exportação padronizada das variáveis de interesse em formato tabular (*Comma-Separated Values* - CSV), dispensando a transcrição manual dos registros e reduzindo o risco de erros de digitação. A extração restringir-se-á exclusivamente às variáveis previamente definidas, e cada recém-nascido receberá um código de identificação sequencial, de modo a assegurar a desvinculação entre os dados clínicos e os identificadores diretos dos participantes já na origem da coleta.

Ressalta-se, ademais, que os escores clínicos empregados como variáveis preditoras, notadamente o nSOFA, o NEWS2 e o qSOFA, não são disponibilizados de forma pré-calculada pela interface do prontuário eletrônico. A API fornece os componentes brutos que integram cada escore, como parâmetros hemodinâmicos, respiratórios, neurológicos e laboratoriais, cabendo ao conector de extração o cálculo e a composição dos escores a partir desses elementos, segundo as fórmulas e os pontos de corte padronizados na literatura. Essa etapa de derivação das variáveis compostas constitui parte integrante da fase de transformação do processo KDD e será implementada e validada de modo explícito no pipeline de pré-processamento.

O *script* de extração e transformação então desenvolvido constitui um *template* funcional, cuja lógica de transformação foi testada e validada, mas no qual os nomes de rota e de campo (a exemplo de */v1/internacoes* e denominações correlatas) figuram como marcadores provisórios (*placeholders*), a serem substituídos pelos identificadores oficiais. Prevê-se, portanto, uma etapa de adaptação e reteste do conector, condicionada ao acesso à especificação técnica definitiva.

Para as variáveis de evolução clínica e de sinais vitais, serão extraídos os registros correspondentes à última evolução diária documentada por profissionais médicos e/ou de enfermagem, preservando-se a periodicidade dos lançamentos ao longo da internação. As variáveis laboratoriais e microbiológicas serão obtidas diretamente dos módulos de resultados de exames do sistema, com a respectiva data e hora de coleta, o que permite o alinhamento temporal entre os achados e a ocorrência do desfecho.

Concluída a extração automatizada, a base de dados será submetida a auditoria e validação manual, realizada semanalmente pela pesquisadora responsável. Nessa etapa, será verificado o correto preenchimento e a consistência dos campos extraídos, com conferência de uma amostra dos registros diretamente no prontuário eletrônico para identificação de dados

ausentes, duplicados ou inconsistentes. As divergências identificadas serão corrigidas e documentadas, e os casos com informações essenciais faltantes serão tratados conforme os critérios de exclusão e as estratégias de imputação previstas no pré-processamento, assegurando a integridade e a rastreabilidade da base analítica.

Para a construção dos modelos, os dados serão importados para o *software* Python (versão 3.11 ou superior) no ambiente Google *Colaboratory*, utilizando as bibliotecas "Pandas", "NumPy" e "Scikit-Learn" para a replicação de modelos, ou seja, conjuntos de códigos de computador já disponibilizados. Por serem dados consideravelmente não lineares, serão realizados cruzamentos multivariados entre as variáveis.

3.8 ALGORITMOS DE APRENDIZADO DE MÁQUINA

A mineração de dados, terceira etapa do processo KDD, representa a fase de descoberta dos padrões por meio da aplicação dos algoritmos. Serão testados os algoritmos de regressão e classificação, na busca pelo melhor resultado na predição da sepse tardia neonatal (Quadro 4).

Quadro 4 – Algoritmos de aprendizado de máquina a serem testados. Teresina, Piauí, Brasil. 2026.

ALGORITMOS DE APRENDIZADO DE MÁQUINA	
Algoritmo	**Descrição**
***Gradient Boosting* (GB)**	Constrói uma série de modelos fracos de árvore de decisão e os combina para formar um modelo forte. Por serem dados não lineares, este algoritmo é particularmente adequado para capturar relações complexas entre as variáveis clínicas neonatais.
XGBoost	Variante otimizada do *Gradient Boosting*, com regularização incorporada e maior eficiência computacional, muito utilizada em dados tabulares de saúde.
Árvore de Decisão (DT)	Divide os dados em subconjuntos puros, permitindo que o modelo tome decisões com base nas características dos dados. Sua alta interpretabilidade é particularmente vantajosa no contexto clínico, pois permite que os profissionais de saúde compreendam os critérios utilizados na classificação, auxiliando no diagnóstico de infecção.
***K-Nearest Neighbors* (KNN)**	Classifica as instâncias com base na maioria das classes de seus vizinhos mais próximos. A proximidade é medida usando uma métrica de distância, como a distância euclidiana.
***Random Forest* (RF)**	Funciona como um conjunto de árvores de decisão. Cria várias árvores de decisão durante o treinamento e as combina visando obter uma decisão mais precisa e estável. É robusto a valores extremos e tem pouca interferência de ruído, possibilitando bons resultados (Bezerra *et al*., 2025).
***Naive Bayes* (NB)**	Utiliza a probabilidade com base no teorema de Bayes, assumindo que as características são independentes. Apresenta alta simplicidade e é indicado quando a precisão é de extrema importância.
Regressão Logística (RL)	Relaciona as variáveis independentes e a probabilidade de pertencer a uma classe de forma aproximadamente linear, sendo utilizada como modelo de referência para comparação basal.
Redes Neurais Artificiais (ANN/MLP)	Arquiteturas densas para captura de relações não lineares complexas, testadas como modelos de aprendizado profundo. Outros algoritmos como Redes Neurais Profundas e Máquina de Vetores de Suporte com Núcleos Complexos também serão avaliados, sendo excluídos caso apresentem resultados abaixo de 70% nas métricas

	avaliadas.

Fonte: elaborado pela autora (2026).

Para a validação do modelo, serão realizados os seguintes passos: inicialmente, será feita a importação das bibliotecas necessárias; em seguida, será realizada a importação da função “train_test_split” do *Scikit-Learn*, para dividir os dados em conjuntos de treinamento e teste, sendo 80% e 20% dos dados, respectivamente. Na sequência, a classe “GridSearchCV” será importada do módulo “model_selection”, técnica que permite encontrar os melhores parâmetros para o modelo por meio da busca na grade de valores especificados. Por serem dados consideravelmente não lineares, serão realizados cruzamentos multivariados entre as variáveis.

3.9 TREINAMENTO, VALIDAÇÃO E MÉTRICAS DE DESEMPENHO

Na quarta etapa do processo KDD, realizar-se-á a avaliação do desempenho dos modelos por meio do método de validação cruzada “k-fold”, com “k” igual a cinco dobras. Nesse método, o banco de dados é subdividido em cinco conjuntos de dados. Em cada uma das cinco validações, uma parte diferente do modelo é escolhida aleatoriamente para representar o grupo de teste, e o restante dos dados faz parte do conjunto de treinamento. As métricas de avaliação final são médias aritméticas dos cinco resultados obtidos ao fim de cada validação. Será utilizada a função “cross_val_score” para realizar a validação cruzada, visando avaliar o desempenho do modelo, especialmente por se tratar de uma amostra considerada limitada. As métricas de avaliação de desempenho que serão realizadas, estão apresentadas no quadro 5.

Quadro 5 – Métricas de avaliação de desempenho dos modelos. Teresina, Piauí, Brasil. 2026.

MÉTRICAS DE AVALIAÇÃO DE DESEMPENHO	
Métrica	**Descrição**
F1-score	Métrica que combina precisão (precision) e recall. É calculado como: 2 × (precisão × recall) / (precisão + recall). O F1-score varia de 0 a 1, em que 1 é a melhor pontuação possível. É a métrica principal neste estudo, dado o desbalanceamento esperado entre as classes (pacientes com e sem sepse tardia).
Acurácia	Mede a proporção de previsões corretas feitas pelo modelo em relação ao total de previsões realizadas.
Precisão (Precision)	É a proporção de verdadeiros positivos, instâncias corretamente classificadas como positivas, em relação a todas as instâncias classificadas como positivas pelo modelo. Indica a capacidade do modelo de não gerar falsos positivos.
Recall (Sensibilidade)	É a proporção de verdadeiros positivos em relação a todos os casos positivos reais. Mede a capacidade do modelo de identificar todos os casos de sepse tardia.
Área Sob a Curva ROC (AUROC)	Representa a taxa de verdadeiros positivos (sensibilidade) no eixo vertical e a taxa de falsos positivos (1 - especificidade) no eixo horizontal. Quanto mais próximo de 1,0, melhor a capacidade discriminatória do modelo.

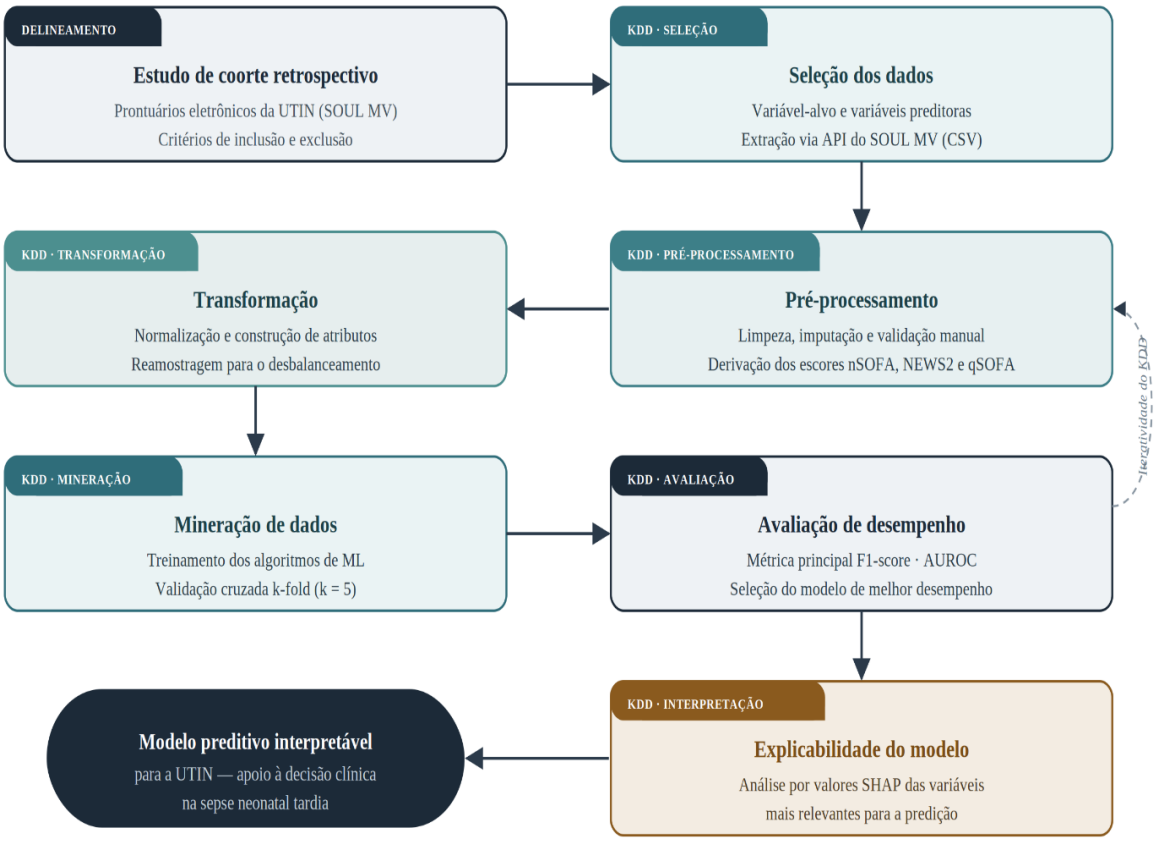
Fonte: elaborado pela autora (2026).

Essas métricas foram escolhidas com o intuito de diminuir o número de falsos positivos, tendo em vista a gravidade da condição a ser detectada, assim como de falsos negativos, para reduzir a possibilidade de aplicação inadequada dos modelos na UTIN.

Os resultados de cada algoritmo serão comparados entre si e apresentados em tabela e graficamente, com visualização das Curvas ROC para todos os modelos. O modelo com melhor desempenho global será selecionado para a análise de explicabilidade por meio de valores SHAP (*SHapley Additive exPlanations*), que permitem identificar quais variáveis mais contribuem para cada predição individual, tornando o modelo compreensível para os profissionais de saúde da UTIN.

Para lidar com o possível desbalanceamento entre classes, dado que nem todos os pacientes desenvolverão sepse tardia, serão avaliadas técnicas de reamostragem sintética e ajuste de pesos de classe, com objetivo de preservar a capacidade preditiva para os casos minoritários, que são justamente aqueles de maior interesse clínico. Por fim, o fluxograma do percurso metodológico está apresentado na Figura 3.

Figura 3 – Fluxograma do percurso metodológico do estudo, organizado segundo o processo KDD. Teresina, Piauí, Brasil. 2026.



Fonte: elaborada pela autora (2026).

3.10 ASPECTOS ÉTICOS

A pesquisa seguirá todos os preceitos éticos preconizados pela Resolução nº 466/2012 do Conselho Nacional de Saúde (CNS) (Brasil, 2012), bem como as normas da Lei nº 13.709/2018 (Lei Geral de Proteção de Dados Pessoais). O projeto será submetido ao Comitê de Ética em Pesquisa (CEP) da Nova Maternidade Dona Evangelina Rosa (NMDER), instituição coparticipante, e em seguida ao Comitê de Ética em Pesquisa da UFPI (CEP/UFPI) via Plataforma Brasil para análise e aprovação antes do início da coleta de dados, garantindo proteção ética e confidencialidade dos dados.

A aplicação de Termo de Consentimento Livre e Esclarecido (TCLE) será dispensada, visto que todas as informações serão coletadas dos prontuários e com o mínimo de riscos para os pacientes, conforme previsto na Resolução CNS nº 510/2016. Os dados serão armazenados em servidor seguro, com acesso restrito aos pesquisadores cadastrados, e anonimizados antes da análise.

4 CRONOGRAMA

Quadro 6 – Cronograma de execução das atividades. Teresina, Piauí, Brasil. 2026.

CRONOGRAMA GERAL DAS ATIVIDADES												
ATIVIDADES	**PERÍODO DE EXECUÇÃO**											
	PRIMEIRO ANO											
	2026										**2027**	
	Mar	**Abr**	**Mai**	**Jun**	**Jul**	**Ago**	**Set**	**Out**	**Nov**	**Dez**	**Jan**	**Fev**
	Mês 1	**Mês 2**	**Mês 3**	**Mês 4**	**Mês 5**	**Mês 6**	**Mês 7**	**Mês 8**	**Mês 9**	**Mês 10**	**Mês 11**	**Mês 12**
Levantamento Bibliográfico												
Elaboração do projeto												
Construção da revisão sistemática												
Cadastro do projeto na Plataforma Brasil												
Submissão e tramitação do Projeto ao CEP da UFPI												
Submissão do artigo de revisão sistemática ao periódico												
Qualificação												
Submissão e tramitação do Projeto ao CEP da NMDER												

ATIVIDADES	SEGUNDO ANO											
	2027										2028	
	Mar	Abr	Mai	Jun	Jul	Ago	Set	Out	Nov	Dez	Jan	Fev
	Mês 13	Mês 14	Mês 15	Mês 16	Mês 17	Mês 18	Mês 19	Mês 20	Mês 21	Mês 22	Mês 23	Mês 24
Levantamento Bibliográfico												
Submissão e tramitação do Projeto ao CEP da NMDER												
Treinamento para a coleta de dados e teste piloto												
Coleta de dados												
Digitação e processamento dos dados												
Análise e discussão dos resultados												
Elaboração do relatório técnico final e para Plataforma Brasil												
Construção e submissão de artigo ao periódico												
Defesa da tese												

Fonte: elaborada pela autora (2026).

5 ORÇAMENTO

Tabela 1 – Orçamento para execução do projeto. Teresina, Piauí, Brasil. 2026.

Material de Consumo	Quantidade (unid.)	Valor unitário (R$)	Valor total (R$)
Computador portátil (*Laptop*)	01	6.500,00	6.500,00
Papel A4 (resma)	03	30,00	90,00
Impressora multifuncional	01	900,00	900,00
Refil para impressora tanque de tinta (preto e colorida)	02	292,00	584,00
Encadernação	03	45,00	135,00
Transporte e deslocamento	40	40,00	1.600,00
Revisão gramatical	02	400,00	800,00
Estatístico	01	3.000,00	3.000,00
Traduções	01	1.000,00	1.000,00
Taxa de submissão	02	500,00	1.000,00
Taxa de publicação	02	1.000,00	2.000,00
		Total	**17.609,00**

Fonte: elaborada pela autora (2026).

Nota: a pesquisa será financiada pelos pesquisadores do estudo.

REFERÊNCIAS

ADAMS, R.; HENRY, K. E.; SRIDHARAN, A.; SOLEIMANI, H.; ZHAN, A.; REIN, N.; *et al*. Prospective, multi-site study of patient outcomes after implementation of the TREWS machine learning-based early warning system for sepsis. **Nature Medicine**, New York, v. 28, n. 7, p. 1455-60, 2022. DOI: 10.1038/s41591-022-01894-0.

AGNIEL, D.; KOHANE, I. S.; WEBER, G. M. Biases in electronic health record data due to processes within the healthcare system: retrospective observational study. **BMJ**, Londres, v. 361, p. k1479, 2018. DOI: 10.1136/bmj.k1479.

AL GHARAIBEH, F. N.; LIU, S.; WYNN, J. L.; AZIZ, K. B. The utility of neonatal sequential organ failure assessment in mortality risk in all neonates with suspected late-onset infection. **Journal of Perinatology**, London, v. 45, n. 10, p. 1438-1442, 2025. DOI: 10.1038/s41372-025-02304-2.

AMANN, J.; BLASIMME, A.; VAYENA, E.; FREY, D.; MADAI, V. I. Explainability for artificial intelligence in healthcare: a multidisciplinary perspective. **BMC Medical Informatics and Decision Making**, London, v. 20, n. 1, art. 310, 2020. DOI: 10.1186/s12911-020-01332-6.

BEAM, A. L.; KOHANE, I. S. Big data and machine learning in health care. **JAMA**, Chicago, v. 319, n. 13, p. 1317-18, 2018. DOI: 10.1001/jama.2017.18391.

BEZERRA, A. D. C.; SOUSA MACIEL, N.; SILVA FILHO, L. S.; SILVA MENDES, A.; GOIS, F. N. B.; SALES DA SILVA, L. M. Efetividade de algoritmos de inteligência artificial para predição de sepse em adultos de unidades de terapia intensiva: revisão de escopo. **Revista Interfaces: Saúde, Humanas e Tecnologia**, v. 11, n. 4, p. 3180-90, 2023. DOI: 10.16891/2317-434X.v11.e3.a2023.pp3180-3190.

BEZERRA, A. D. C.; SALES DA SILVA, L. M.; MAIA PINTO, F. J.; OLIVEIRA GONÇALVES, R. V. Predição de sepse em pacientes de unidade de terapia intensiva: desenvolvimento e avaliação de algoritmos de inteligência artificial. **Revista de Ciências Médicas e Biológicas**, Salvador, v. 24, n. 1, p. 111-18, jan./abr. 2025. DOI: 10.9771/cmbio.v24i1.60246.

BRASIL. Ministério da Saúde. **Limite de viabilidade no moderno cuidado intensivo neonatal**: análise além da idade gestacional. Comunicação em Ciências da Saúde, Brasília, DF, v. 22, supl. esp. 1, 2011. Disponível em: https://www.saude.df.gov.br/documents/37101/87400/Limite+de+Viabilidade+em+Neonatologia.pdf/35da70b0-61a1-646e-018d-9e48b685baaa?t=1648646097907. Acesso em: 20 maio 2026.

BRASIL. Ministério da Saúde. Secretaria de Vigilância em Saúde. **Manual de vigilância do óbito infantil e fetal e do Comitê de Prevenção do Óbito Infantil e Fetal**. 2. ed. Brasília, DF: Ministério da Saúde, 2009. Disponível em: https://bvsms.saude.gov.br/bvs/publicacoes/vigilancia_obito_infantil_fetal.pdf. Acesso em: 20 maio 2026.

BRASIL. **Resolução nº 466, de 12 de dez de 2012**. Estabelece Critérios sobre pesquisas envolvendo seres humanos. Bioética, Brasília, DF: Ministério da Saúde, n. 12, p.59, 2012. Disponível em: https://bvsms.saude.gov.br/bvs/saudelegis/cns/2013/res0466_12_12_2012.html. Acesso em: 20 maio 2026.

BRASIL. **Lei nº 13.709, de 14 de agosto de 2018**. Lei Geral de Proteção de Dados Pessoais (LGPD). Diário Oficial da União, Brasília, DF, 15 ago. 2018. Disponível em: https://www.planalto.gov.br/ccivil_03/_ato2015-2018/2018/lei/l13709.htm. Acesso em: 4 jul. 2026.

BRITISH PAEDIATRIC NEUROLOGY ASSOCIATION. **Child's Glasgow Coma Scale**: revised chart. London: BPNA, 2001.

BRITO, L. K. T.; FREITAS, L. L.; CIARLINI, N. S. C.; ARAÚJO, A. R.; MAIA, E. M. C.; NOBRE, K. S. S. Fatores associados aos óbitos por sepse precoce e tardia em unidade de terapia intensiva neonatal. **Revista de Enfermagem UFPE On Line**, Recife, v. 18, p. e257956, 2024. DOI: 10.5205/1981-8963.2024.257956.

BRASIL. Ministério da Saúde. Gabinete do Ministro. **Portaria GM/MS nº 5.350, de 12 de setembro de 2024**: institui a Rede Alyne, no âmbito do Sistema Único de Saúde (SUS), para a atenção à saúde materna e infantil. Diário Oficial da União, Brasília, DF, 13 set. 2024. Disponível em: https://bvsms.saude.gov.br/bvs/saudelegis/gm/2024/prt5350_13_09_2024.html. Acesso em: 4 jul. 2026.

CELIK, I. H.; HANNA, M.; CANPOLAT, F. E.; PAMMI, M. Diagnosis of neonatal sepsis: the past, present and future. **Pediatric Research**, v. 91, n. 2, p. 337-350, 2022. DOI: 10.1038/s41390-021-01696-z.

CHAITHAWEESUP, P.; MANEENIL, G.; THATRIMONTRICHAI, A.; PRADITAUKRIT, M.; PAKHATHIRATHIEN, P.; CHAREESRI, P.; *et al*. Predictive performance of the PSU-neonatal early warning score in identifying newborns requiring intensive care. **Frontiers in Pediatrics**, Lausanne, v. 14, art. 1804592, 2026. DOI: 10.3389/fped.2026.1804592.

CHAWLA, N. V.; BOWYER, K. W.; HALL, L. O.; KEGELMEYER, W. P. SMOTE: synthetic minority over-sampling technique. **Journal of Artificial Intelligence Research**, v. 16, p. 321-357, 2002. DOI: 10.1613/jair.953.

COGGINS, S. A.; GLASER, K. Updates in late-onset sepsis: risk assessment, therapy, and outcomes. **NeoReviews**, Itasca, v. 23, n. 11, p. e738-e755, 2022. DOI: 10.1542/neo.23-10-e738.

CONCEIÇÃO, H. N.; DIOGO, M. P. S.; SILVA, P. J.; ARAÚJO, L. E. R.; DORNELES, I. A. B.; DORNELES NETO, J. S.; *et al*. Sepse neonatal: desafios no diagnóstico e tratamento. **Brazilian Journal of Implantology and Health Sciences**, v. 6, n. 2, p. 1243-51, 2024. DOI: 10.36557/2674-8169.2024v6n2p1243-1251.

DATASUS. **Sistema de Informação de Mortalidade:** Óbitos Infantis. Brasília: Ministério da Saúde, 2024. Disponível em: http://tabnet.datasus.gov.br/cgi/tabcgi.exe?sim/cnv/inf10uf.def. Acesso em: 29 mai. 2026.

DE ROSE, D. U.; RONCHETTI, M. P.; MARTINI, L.; RECHICHI, J.; IANNETTA, M.; DOTTA, A.; *et al*. Diagnosis and management of neonatal bacterial sepsis: current challenges and future perspectives. **Tropical Medicine and Infectious Disease**, Basel, v. 9, n. 9, 2024. DOI: 10.3390/tropicalmed9090199.

DEVIA-JARAMILLO, G. A.; ERAZO-GUERRERO, L.; LAGUADO-CASTRO, V.; ALFONSO-PARADA, J. M. Evaluating sepsis mortality predictions from the emergency department: a retrospective cohort study comparing qSOFA, the National Early Warning Score, and the International Early Warning Score. **Journal of Clinical Medicine**, Basel, v. 14, n. 14, art. 4869, 2025. DOI: 10.3390/jcm14144869.

DURR, D.; NIEMI, T.; DESPRAZ, J.; TUSGUL, S.; DAMI, F.; AKROUR, R.; *et al*. National Early Warning Score (NEWS) outperforms Quick Sepsis-Related Organ Failure (qSOFA) score for early detection of sepsis in the emergency department. **Antibiotics**, Basel, v. 11, n. 11, art. 1518, 2022. DOI: 10.3390/antibiotics11111518.

EL-SAPPAGH, S.; EL-MASRI, S.; RIAD, A. M.; ELMOGY, M. Data mining and knowledge discovery: applications, techniques, challenges and process models in healthcare. **International Journal of Engineering Research and Applications**, v. 3, n. 3, p. 900-906, 2013. Disponível em: https://api.semanticscholar.org/CorpusID:3200894. Acesso em: 20 jun. 2026.

ESTEVA, A.; KUPREL, B.; NOVOA, R. A.; KO, J.; SWETTER, S. M.; BLAU, H. M.; *et al*. Dermatologist-level classification of skin cancer with deep neural networks. **Nature**, London, v. 542, n. 7639, p. 115-18, 2017. DOI: 10.1038/nature21056.

FAYYAD, U.; PIATETSKY-SHAPIRO, G.; SMYTH, P. From data mining to knowledge discovery in databases. **AI Magazine**, v. 17, n. 3, p. 37-54, 1996. DOI: 10.1609/aimag.v17i3.1230.

FLEISCHMANN, C.; REICHERT, F.; CASSINI, A.; HORNER, R.; HARDER, T.; MARKWART, R.; *et al*. Global incidence and mortality of neonatal sepsis: a systematic review and meta-analysis. **Archives of Disease in Childhood**, v. 106, n. 8, p. 745-52, 2021. DOI: 10.1136/archdischild-2020-320217.

FLEISCHMANN-STRUZEK, C.; GOLDFARB, D. M.; SCHLATTMANN, P.; SCHLAPBACH, L. J.; REINHART, K.; KISSOON, N. The global burden of paediatric and neonatal sepsis: a systematic review. **The Lancet Respiratory Medicine**, v. 6, n. 3, p. 223-30, 2018. DOI: 10.1016/S2213-2600(18)30063-8.

FLEUREN, L. M.; KLAUSCH, T. L. T.; ZWAGER, C. L.; SCHOONMADE, L. J.; GUO, T.; ROGGEVEEN, L. F.; *et al*. Machine learning for the prediction of sepsis: a systematic review and meta-analysis of diagnostic test accuracy. **Intensive Care Medicine**, Heidelberg, v. 46, n. 3, p. 383-400, 2020. DOI: 10.1007/s00134-019-05872-y.

HENRY, K. E.; HAGER, D. N.; PRONOVOST, P. J.; SARIA, S. A targeted real-time early warning score (TREWScore) for septic shock. **Science Translational Medicine**, Washington, v. 7, n. 299, art. 299ra122, 2015. DOI: 10.1126/scitranslmed.aab3719.

HUNCIKOVA, Z.; VATNE, A.; STENSVOLD, H. J.; LANG, A. M.; STORDAL, K.; BRUNGOT STORM, H.; *et al*. Late-onset sepsis in very preterm infants in Norway in 2009-2018: a population-based study. **Archives of Disease in Childhood - Fetal and Neonatal Edition**, v. 108, n. 5, p. 478-84, 2023. DOI: 10.1136/archdischild-2022-324977.

HUSAIN, A.; KNAKE, L.; SULLIVAN, B.; BARRY, J.; BEAM, K.; HOLMES, E.; *et al*. AI models in clinical neonatology: a review of modeling approaches and a consensus proposal for standardized reporting of model performance. **Pediatric Research**, London, v. 98, n. 2, p. 412-22, 2025. DOI: 10.1038/s41390-024-03774-4.

JAMES, G.; WITTEN, D.; HASTIE, T.; TIBSHIRANI, R. **An Introduction to Statistical Learning: with Applications in R**. New York: Springer, 2013. DOI: https://doi.org/10.1007/978-1-4614-7138-7.

KUHN, Max; JOHNSON, Kjell. **Applied Predictive Modeling**. New York: Springer, 2013. DOI: https://doi.org/10.1007/978-1-4614-6849-3.

KAINTH, D.; GUPTA, A.; SINGH, P.; PRAKASH, S.; THUKRAL, A.; DEORARI, A.; *et al*. A machine learning model for prediction of early-onset neonatal sepsis in low- and middle-income countries: development and validation study. **medRxiv**, Cold Spring Harbor, 2025. Preprint. DOI: 10.1101/2025.09.20.25335989.

KAUSCH, S. L.; BRANDBERG, J. G., QIU, J.; PANDA, A.; BINAI, A.; ISLER, J.; *et al*. Cardiorespiratory signature of neonatal sepsis: development and validation of prediction models in 3 NICUs. **Pediatric Research**, v. 93, n. 7, p. 1913-21, 2023. DOI: 10.1038/s41390-022-02444-7.

KOMOROWSKI, M.; CELI, L. A.; BADAWI, O.; GORDON, A. C.; FAISAL, A. A. The Artificial Intelligence Clinician learns optimal treatment strategies for sepsis in intensive care. **Nature Medicine**, New York, v. 24, n. 11, p. 1716-20, 2018. DOI: 10.1038/s41591-018-0213-5.

KLINGER, G.; REICHMAN, B.; NORMAN, M.; KUSUDA, S.; BATTIN, M.; HELENIUS, K.; *et al*. Late-onset sepsis among extremely preterm infants of 24-28 weeks gestation: an international comparison in 10 high-income countries. **Neonatology**, Basel, v. 121, n. 6, p. 761-771, 2024. DOI: 10.1159/000539245.

KURUL, Ş.; REIJNIERSE, J. J.; KOPPENS, H. J.; ONLAND, W.; SIMONS, S. H. P.; REISS, I. K. M.; *et al*. Assessing neonatal Sequential Organ Failure (nSOFA) scores in suspected late-onset neonatal sepsis among preterm infants: implications for morbidity and mortality. **BMJ Paediatrics Open**, London, v. 8, n. 1, art. e002884, 2024. DOI: 10.1136/bmjpo-2024-002884.

LAMBERT, C.; BEAN D.; SHEK, A.; BENDAYAN, R.; HEMINGWAY, H.; YEUNG, J. A. *et al*. Foresight - a generative pretrained transformer for modelling of patient timelines using electronic health records: a retrospective modelling study. **The Lancet Digital Health**, Londres, v. 6, n. 3, 2024. DOI: 10.1016/S2589-7500(24)00025-6.

LeCUN, Y.; BENGIO, Y.; HINTON, G. Deep learning. **Nature**, London, v. 521, n. 7553, p. 436-44, 2015. DOI: 10.1038/nature14539.

LUNDBERG, S. M.; LEE, S.-I. A unified approach to interpreting model predictions. **Advances in Neural Information Processing Systems**, v. 30, p. 4765-4774, 2017. DOI: 10.48550/arXiv.1705.07874.

MALAQUIAS, C. F. V.; ARAUJO, M. A.; DONATO, C. S.; SILVA, G. F. R.; BELO, F. F. R.; DINIZ, M. L. P. *et al*. Fatores de risco da sepse neonatal tardia: uma revisão narrativa. **Revista Eletrônica Acervo Saúde**, v. 15, n. 2, p. 1-8, 2022. DOI: 10.25248/reas.e9739.2022.

MANDAIR, D.; TIWARI, P.; SIMON, S.; COLBORN, K. L.; ROSENBERG, M. A. Prediction of incident myocardial infarction using machine learning applied to harmonized electronic health record data. **BMC Medical Informatics and Decision Making**, Londres, v. 20, n. 252, 2020. DOI: 10.1186/s12911-020-01268-x.

McGOVERN, M.; GIANNONI, E.; KUESTER, H.; TURNER, M. A.; VAN DEN HOOGEN, A.; BLISS, J. M.; *et al*. Challenges in developing a consensus definition of neonatal sepsis. **Pediatric Research**, London, v. 88, n. 1, p. 14-26, 2020. DOI: 10.1038/s41390-020-0785-x.

MEEUS, M.; BEIRNAERT, C.; MAHIEU, L.; LAUKENS, K.; MEYSMAN, P.; MULDER, A.; *et al*. Clinical decision support for improved neonatal care: the development of a machine learning model for the prediction of late-onset sepsis and necrotizing enterocolitis. **The Journal of Pediatrics**, New York, v. 266, art. 113869, 2024. DOI: 10.1016/j.jpeds.2023.113869.

MERHY, E. E. **Saúde: a cartografia do trabalho vivo**. São Paulo: Hucitec, 2002.

MOLLOY, E. J.; WYNN, J. L.; BLISS, J.; KOENIG, J. M.; KEIJ, F. M.; McGOVERN, M.; *et al*. Neonatal sepsis: need for consensus definition, collaboration and core outcomes. **Pediatric Research**, London, v. 88, n. 1, p. 2-4, 2020. DOI: 10.1038/s41390-020-0850-5.

MOOR, M.; BANERJEE, O.; ABAD, Z. S. H.; KRUMHOLZ, H. M.; LESKOVEC, J.; TOPOL, E. J.; *et al*. Foundation models for generalist medical artificial intelligence. **Nature**, London, v. 616, n. 7956, p. 259-65, 2023. DOI: 10.1038/s41586-023-05881-4.

MOORMAN, J. R.; CARLO, W. A.; KATTWINKEL, J.; SCHELONKA, R. L.; PORCELLI, P. J.; NAVARRETE, C. T.; *et al*. Mortality reduction by heart rate characteristic monitoring in very low birth weight neonates: a randomized trial. **The Journal of Pediatrics**, New York, v. 159, n. 6, p. 900-906.e1, 2011. DOI: 10.1016/j.jpeds.2011.06.044.

MU, C.; LIU, F.; TIAN, T.; FENG, M.; DANG, X.; XIE, L.; *et al*. Analysis of the global burden and key risk factors of neonatal sepsis and other neonatal infections in 204 countries and territories, 1990-2021. **Frontiers in Medicine**, Lausanne, v. 12, art. 1536948, 2025. DOI: 10.3389/fmed.2025.1536948.

MUKHERJEE, P.; HUMBERT-DROZ, M.; CHEN, J. H.; GEVAERT, O. SCOPE: predicting future diagnoses in office visits using electronic health records. **Scientific Reports**, Londres, v. 13, 2023. DOI: 10.1038/s41598-023-38257-9.

NIKRAVANGOLSEFID, N.; REDDY, S.; TRUONG, H. H.; CHARKVIANI, M.; NINAN, J.; PROKOP, L. J.; *et al*. Machine learning for predicting mortality in adult critically ill patients with sepsis: a systematic review. **Journal of Critical Care**, Philadelphia, v. 84, art. 154889, 2024. DOI: 10.1016/j.jcrc.2024.154889.

NWANKWO, U. C.; NGENE, N. J.; ONUORA, J. N. Applications of Knowledge Discovery and Database (KDD) in Clinical Decision Support Systems. **Engineering and Technology Journal**, v. 8, n. 11, p. 3200-3210, 2023. DOI: 10.47191/etj/v8i11.02.

OBERMEYER, Z.; POWERS, B.; VOGELI, C.; MULLAINATHAN, S. Dissecting racial bias in an algorithm used to manage the health of populations. **Science**, Washington, v. 366, n. 6464, p. 447-53, 2019. DOI: 10.1126/science.aax2342.

PENG, Z.; VARISCO, G.; LONG, X.; LIANG, R. H.; KOMMERS, D.; COTTAAR, W.; *et al*. A continuous late-onset sepsis prediction algorithm for preterm infants using multi-channel physiological signals from a patient monitor. **IEEE Journal of Biomedical and Health Informatics**, v. 27, n. 1, p. 550-61, 2023. DOI: 10.1109/JBHI.2022.3216055.

POGGI, C.; SARCINA, D.; MISELLI, F.; CIARCIÀ, M.; DANI, C. Neonatal Sequential Organ Failure Assessment Score predicts respiratory outcomes in preterm newborns with late-onset sepsis: a retrospective study. **Neonatology**, Basel, v. 122, n. 1, p. 56-65, 2025. DOI: 10.1159/000539526.

PROCIANOY, R. S.; SILVEIRA, R. C. The challenges of neonatal sepsis management. **Jornal de Pediatria**, Rio de Janeiro, v. 96, supl. 1, p. 80-6, 2020. DOI:

10.1016/j.jped.2019.10.004.

RAJKOMAR, A.; DEAN, J.; KOHANE, I. Machine learning in medicine. **The New England Journal of Medicine**, Boston, v. 380, n. 14, p. 1347-58, 2019. DOI: 10.1056/NEJMra1814259.

RATURI, A.; CHANDRAN, S. Neonatal sepsis: aetiology, pathophysiology, diagnostic advances and management strategies. **Clinical Medicine Insights: Pediatrics**, London, v. 18, art. 11795565241281337, p. 1-11, 2024. DOI: 10.1177/11795565241281337.

RUGOLO, L. M. S. S.; BENTLIN, M. R. Projeto DownLOS: redução da sepse tardia em prematuros de muito baixo peso em centros da Rede Brasileira de Pesquisas Neonatais. **Jornal UNESP**, Botucatu, 12 mar. 2026. Disponível em: https://jornal.unesp.br/2026/03/12/estudo-coordenado-por-pesquisadoras-da-unesp-reduz-mortalidade-em-utis-neonatais. Acesso em: 21 jun. 2026.

RUDIN, C. Stop explaining black box machine learning models for high stakes decisions and use interpretable models instead. **Nature Machine Intelligence**, London, v. 1, n. 5, p. 206-215, 2019. DOI: 10.1038/s42256-019-0048-x.

RUSSELL, N. J.; STÖHR, W.; PLAKKAL, N.; COOK, A.; BERKLEY, J. A.; ADHISIVAM, B.; AGARWAL, R.; *et al*. Patterns of antibiotic use, pathogens, and prediction of mortality in hospitalized neonates and young infants with sepsis: a global neonatal sepsis observational cohort study (NeoOBS). **PLOS Medicine**, San Francisco, v. 20, n. 6, e1004179, 2023. DOI: 10.1371/journal.pmed.1004179.

RUSSELL, S. J.; NORVIG, P. **Artificial intelligence**: a modern approach. 4. ed. Hoboken: Pearson, 2021.

SANCHEZ-PINTO, L. N.; BENNETT, T. D.; DeWITT, P. E.; FAUSTINO, E. V. S.; ROGERSON, C. M.; HALEY, K. J.; *et al*. Development and validation of the Phoenix criteria for pediatric sepsis and septic shock. **JAMA**, Chicago, v. 331, n. 8, p. 675-86, 2024. DOI: 10.1001/jama.2024.0196.

SCHINKEL, M.; VAN DER POLL, T.; WIERSINGA, W. J. Artificial intelligence for early sepsis detection: a word of caution. **American Journal of Respiratory and Critical Care Medicine**, New York, v. 207, n. 7, p. 853-54, 2023. DOI: 10.1164/rccm.202212-2284VP.

SCHLAPBACH, L. J.; WATSON, R. S.; SORCE, L. R.; ARGENT, A. C.; MENON, K.; HALL, M. W.; *et al*. International consensus criteria for pediatric sepsis and septic shock. **JAMA**, Chicago, v. 331, n. 8, p. 665-74, 2024. DOI: 10.1001/jama.2024.0179.

SHANE, A. L.; SÁNCHEZ, P. J.; STOLL, B. J. Neonatal sepsis. **The Lancet**, v. 390, n. 10104, p. 1770-80, 2017. DOI: 10.1016/S0140-6736(17)31002-4.

SHARDA, R.; DELEN, D.; TURBAN, E. **Analytics, data science & artificial intelligence:** systems for decision support. 11. ed. Harlow: Pearson, 2021.

SHU, C. H.; ZEBDA, R.; ESPINOSA, C.; REISS, J.; DEBUYSERIE, A.; REBER, K.; *et al*. Early prediction of mortality and morbidities in VLBW preterm neonates using machine

learning. **Pediatric Research**, v. 97, p. 2056-64, 2025. DOI: 10.1038/s41390-024-03604-7.

SILVEIRA, R. C.; PROCIANOY, R. S. Uma revisão atual sobre sepse neonatal. **Boletim Científico de Pediatria**, Porto Alegre, v. 1, n. 1, p. 29-35, 2012. Disponível em: https://www.sprs.com.br/sprs2013/bancoimg/131210152124bcped_12_01_06.pdf. Acesso em: 29 mai. 2026.

SINGER, M.; DEUTSCHMAN, C. S.; SEYMOUR, C. W.; SHANKAR-HARI, M.; ANNANE, D.; BAUER, M.; *et al*. The Third International Consensus Definitions for Sepsis and Septic Shock (Sepsis-3). **JAMA**, Chicago, v. 315, n. 8, p. 801-10, 2016. DOI: 10.1001/jama.2016.0287.

SNOWDEN, J. M.; KLEBANOFF, M. A. Accurate identification of cohort study designs in perinatal research: a practical guide. **American Journal of Obstetrics and Gynecology**, New York, v. 227, n. 2, p. 231-235.e1, 2022. DOI: 10.1016/j.ajog.2022.03.014.

STOCKER, M.; ROSA-MANGERET, F.; AGYEMAN, P. K. A.; McDOUGALL, J.; BERGER, C.; GIANNONI, E. Management of neonates at risk of early onset sepsis: a probability-based approach and recent literature appraisal. **European Journal of Pediatrics**, Berlin, v. 183, n. 12, p. 5517-29, 2024. DOI: 10.1007/s00431-024-05811-0.

STRUNK, T.; MOLLOY, E. J.; MISHRA, A.; BHUTTA, Z. A. Neonatal bacterial sepsis. **The Lancet**, London, v. 404, n. 10449, p. 277-93, 2024. DOI: 10.1016/S0140-6736(24)00495-1.

SULLIVAN, B. A.; KAUSCH, S. L.; FAIRCHILD, K. D. Artificial and human intelligence for early identification of neonatal sepsis. **Pediatric Research**, v. 93, n. 2, p. 350-56, 2023. DOI: 10.1038/s41390-022-02274-7.

TATMAN, A.; WARREN, A.; WILLIAMS, A.; POWELL, J. E.; WHITEHOUSE, W. Development of a modified paediatric coma scale in intensive care clinical practice. **Archives of Disease in Childhood**, London, v. 77, n. 6, p. 519-521, 1997. DOI: 10.1136/adc.77.6.519.

TEASDALE, G.; JENNETT, B. Assessment of coma and impaired consciousness: a practical scale. **The Lancet**, London, v. 304, n. 7872, p. 81-84, 1974. DOI: 10.1016/S0140-6736(74)91639-0.

TOPOL, E. J. High-performance medicine: the convergence of human and artificial intelligence. **Nature Medicine**, New York, v. 25, n. 1, p. 44-56, 2019. DOI: 10.1038/s41591-018-0300-7.

TUDOR, S.; BHATIA, R.; LIEM, M.; WANI, T. A.; BOYD, J.; KHAN, U. R. Opportunities and challenges of using artificial intelligence in predicting clinical outcomes and length of stay in neonatal intensive care units: systematic review. **Journal of Medical Internet Research**, Toronto, v. 27, art. e63175, 2025. DOI: 10.2196/63175.

VAN DEN BERG, M. A. M.; MEDINA, O. A. G.; LOOHUIS, I. P.; VAN DER FLIER, M.; DUDINK, J.; BENDERS, M. J. N. L.; *et al*. Development and clinical impact assessment of a machine-learning model for early prediction of late-onset sepsis. **Computers in Biology and Medicine**, v. 163, p. 107156, 2023. DOI: 10.1016/j.compbiomed.2023.107156.

WEISS, S. L.; PETERS, M. J.; OCZKOWSKI, S. J.; AGUS, M. S. D.; FLORI, H. R.; INWALD, D. P.; *et al*. Surviving Sepsis Campaign international guidelines for the management of sepsis and septic shock in children 2026. **Pediatric Critical Care Medicine**, Philadelphia, 2026. DOI: 10.1097/PCC.0000000000003927.

WILLEY, E.; MITCHELL, M.; EHLERT, C.; SWOVELAND, J.; ZEMBLES, T. Time to positive blood cultures in neonatal sepsis evaluations. **Journal of Perinatology**, London, v. 45, n. 7, p. 993-996, 2025. DOI: 10.1038/s41372-025-02323-z.

WONG, A.; OTLES, E.; DONNELLY, J. P.; KRUMM, A.; McCULLOUGH, J.; DeTROYER-COOLEY, O.; *et al*. External validation of a widely implemented proprietary sepsis prediction model in hospitalized patients. **JAMA Internal Medicine**, Chicago, v. 181, n. 8, p. 1065-70, 2021. DOI: 10.1001/jamainternmed.2021.2626.

WORLD HEALTH ORGANIZATION (WHO). **Neonatal sepsis**. Geneva: WHO, 2021. Disponível em: https://platform.who.int/data/maternal-newborn-child-adolescent-ageing/indicator-explorer-new/mca/number-of-neonatal-deaths---by-cause. Acesso em: 29 mai. 2026.

WORLD HEALTH ORGANIZATION. **WHO bacterial priority pathogens list, 2024**: bacterial pathogens of public health importance to guide research, development, and strategies to prevent and control antimicrobial resistance. Geneva: World Health Organization, 2024. Disponível em: https://www.who.int/publications/i/item/9789240093461. Acesso em: 29 jun. 2026.

WYNN, J. L. Defining neonatal sepsis. **Current Opinion in Pediatrics**, Philadelphia, v. 28, n. 2, p. 135-40, 2016. DOI: 10.1097/MOP.0000000000000315.

WYNN, J. L.; POLIN, R. A. A neonatal sequential organ failure assessment score predicts mortality to late-onset sepsis in preterm very low birth weight infants. **Pediatric Research**, London, v. 88, n. 1, p. 85-90, 2020. DOI: 10.1038/s41390-019-0517-2.

WYNN, J. L.; WONG, H. R.; SHANLEY, T. P.; BIZZARRO, M. J.; SAIMAN, L.; POLIN, R. A. Time for a neonatal-specific consensus definition for sepsis. **Pediatric Critical Care Medicine**, Philadelphia, v. 15, n. 6, p. 523-28, 2014. DOI: 10.1097/PCC.0000000000000157.

YAMAN, S.; GUNEY VARAL, I.; TUNÇ, G.; ÖREN, A.; BAGCI, O.; GÜLER KAZANCI, E. Prediction of mortality by nSOFA Score for late-onset sepsis in very low birth weight infants. **Journal of Infection in Developing Countries**, Sassari, v. 19, n. 12, p. 1801-1808, 2025. DOI: 10.3855/jidc.21217.

APÊNDICE A – INSTRUMENTO DE COLETA DE DADOS DOS PRONTUÁRIOS ELETRÔNICOS

PARTE I – INSTRUÇÕES DE PREENCHIMENTO

Como usar este instrumento:

1. Cada linha da coleta de dados corresponde a UM recém-nascido (um prontuário).
2. Preencha o "id_prontuario" com um código anonimizado (ex.: RN001, RN002...). Nunca use nome ou CPF.
3. Campos com lista suspensa (Sim/Não, categorias) devem ser preenchidos conforme os valores permitidos indicados no dicionário de variáveis.
4. Campos numéricos devem ser preenchidos apenas com números (sem unidade, sem vírgula como separador de milhar).
5. Se um dado não estiver disponível no prontuário, deixe o campo em branco – não escreva "N/A" ou "-". O tratamento de dados ausentes será feito na etapa de pré-processamento do pipeline de Python.
6. Consulte o dicionário de variáveis para a definição operacional de cada campo antes de preencher.
7. Ao final da coleta, exporte os dados como CSV (ou use o .xlsx diretamente) para alimentar o pipeline de aprendizado de máquina.

Lembrete ético: os dados aqui inseridos já devem estar anonimizados. Armazene este arquivo apenas em ambiente seguro, com acesso restrito aos pesquisadores cadastrados no projeto (CEP/UFPI e CEP/NMDER), conforme a LGPD.

PARTE II – DICIONÁRIO DE VARIÁVEIS

Variável	Tipo	Valores permitidos	Descrição / definição operacional
ID			
id_prontuario	texto	-	Código anonimizado do prontuário (não usar nome/CPF).
data_coleta	data	-	Data em que o dado foi extraído do prontuário.
pesquisador	texto	-	Iniciais do pesquisador responsável pela coleta.
Demográficas e do parto			
sexo_rn	lista	Masculino;Feminino	Sexo do recém-nascido.
idade_gestacional_semanas	numero	-	Idade gestacional ao nascer, em semanas completas.
peso_nascimento_g	numero	-	Peso ao nascer, em gramas.
apgar_1min	numero	-	Índice de Apgar no 1º minuto (0-10).
apgar_5min	numero	-	Índice de Apgar no 5º minuto (0-10).
tipo_parto	lista	Vaginal;Cesariana	Tipo de parto.
idade_materna	numero	-	Idade materna em anos completos.
raca_cor_rn	lista	Branca;Preta;Parda;Amarela;Indígena;Não informado	Raça/cor do recém-nascido.
raca_cor_mae	lista	Branca;Preta;Parda;Amarela;Indígena;Não informado	Raça/cor da mãe.
num_gestacoes_anteriores	numero	-	Número de gestações anteriores.
itu_materna	sim_nao	Sim;Não	Infecção do trato urinário materna na gestação.
rotura_prematura_membranas	sim_nao	Sim;Não	Rotura prematura de membranas ovulares.
corioamnionite	sim_nao	Sim;Não	Corioamnionite.
pre_eclampsia	sim_nao	Sim;Não	Pré-eclâmpsia materna.
atb_materno_intraparto	sim_nao	Sim;Não	Uso de antibiótico materno intraparto.
Clínicas e de internação			
tempo_internacao_utin_dias	numero	-	Tempo total de internação na UTIN,

Variável	Tipo	Valores permitidos	Descrição / definição operacional
			em dias.
vm_invasiva	sim_nao	Sim;Não	Uso de ventilação mecânica invasiva.
vm_invasiva_dias	numero	-	Número de dias em ventilação mecânica invasiva.
cateter_venoso_central	sim_nao	Sim;Não	Uso de cateter venoso central.
cvc_dias	numero	-	Dias de permanência do cateter venoso central.
cateter_umbilical	sim_nao	Sim;Não	Uso de cateter umbilical.
npt	sim_nao	Sim;Não	Nutrição parenteral total.
npt_dias	numero	-	Número de dias em nutrição parenteral total.
atb_previo_sepse_tardia	sim_nao	Sim;Não	Uso de antibióticos previamente à sepse tardia.
classes_atb_usadas	texto	-	Classes de antibióticos utilizadas (texto livre ou separado por ;).
historia_sugestiva_infeccao	sim_nao	Sim;Não	História sugestiva de infecção.
criterios_disfuncao_organica	sim_nao	Sim;Não	Presença de critérios de disfunção orgânica.
enterocolite_necrosante	sim_nao	Sim;Não	Diagnóstico de enterocolite necrosante.
hemorragia_intraventricular_grau	lista	Ausente;I;II;III;IV	Grau de hemorragia intraventricular (Papile).
temperatura_min_c	numero	-	Temperatura corporal mínima durante a internação (°C).
temperatura_max_c	numero	-	Temperatura corporal máxima durante a internação (°C).
temperatura_media_c	numero	-	Temperatura corporal média durante a internação (°C).
frequencia_cardiaca_bpm	numero	-	Frequência cardíaca

Variável	Tipo	Valores permitidos	Descrição / definição operacional
			(bpm), na janela de avaliação.
frequencia_respiratoria_irpm	numero	-	Frequência respiratória (irpm), na janela de avaliação.
spo2_pct	numero	-	Saturação periférica de oxigênio (%).
pas_mmhg	numero	-	Pressão arterial sistólica (mmHg).
pad_mmhg	numero	-	Pressão arterial diastólica (mmHg).
uso_vasopressor	sim_nao	Sim;Não	Uso de vasopressor.
droga_vasopressor	texto	-	Droga vasopressora utilizada (se aplicável).
surfactante_exogeno	sim_nao	Sim;Não	Uso de surfactante exógeno.
episodios_apneia_bradicardia_24h	numero	-	Número de episódios de apneia/bradicardia por 24h.
tempo_diagnostico_sepse_dias	numero	-	Dias desde a internação até o diagnóstico de sepse (se houver).
Laboratoriais			
leucocitos_totais	numero	-	Contagem de leucócitos totais (/mm³).
neutrofilos_segmentados_pct	numero	-	Neutrófilos segmentados (%).
neutrofilos_bastoes_pct	numero	-	Neutrófilos bastonetes (%).
relacao_it	numero	-	Relação Imaturos/Totais (índice de Rodwell).
plaquetas	numero	-	Contagem de plaquetas (/mm³).
pcr_mg_l	numero	-	Proteína C Reativa (mg/L).
pct_ng_ml	numero	-	Procalcitonina (ng/mL), quando disponível.
glicemia_mg_dl	numero	-	Glicemia (mg/dL).
creatinina_mg_dl	numero	-	Creatinina sérica (mg/dL).
bilirrubina_total_mg_dl	numero	-	Bilirrubina total

Variável	Tipo	Valores permitidos	Descrição / definição operacional
			(mg/dL).
ph_sangue	numero	-	pH do sangue (arterial ou venoso).
lactato_mmol_l	numero	-	Lactato sérico (mmol/L).
hemoglobina_g_dl	numero	-	Hemoglobina (g/dL).
hematocrito_pct	numero	-	Hematócrito (%).
sodio_meq_l	numero	-	Sódio sérico (mEq/L).
potassio_meq_l	numero	-	Potássio sérico (mEq/L).
calcio_ionizado_mmol_l	numero	-	Cálcio ionizado (mmol/L).
tgo_u_l	numero	-	TGO/AST (U/L).
tgp_u_l	numero	-	TGP/ALT (U/L).
relacao_neutrofilos_linfocitos	numero	-	Relação neutrófilos/linfócitos.
Microbiológicas			
hemocultura_resultado	lista	Positiva;Negativa;Não realizada	Resultado da hemocultura.
agente_isolado	texto	-	Agente microbiológico isolado (se hemocultura positiva).
perfil_sensibilidade_atb	texto	-	Perfil de sensibilidade antimicrobiana.
historico_iras	sim_nao	Sim;Não	Histórico de infecção relacionada à assistência à saúde.
colonizacao_scn_klebsiella	sim_nao	Sim;Não	Colonização por S. coagulase-negativo ou Klebsiella sp.
Escores clínicos			
glasgow_neonatal_adaptada	numero	-	Escala de Coma de Glasgow neonatal adaptada (escore total).
news2_score	numero	-	NEWS2 (National Early Warning Score 2).
qsofa_score	numero	-	qSOFA (0-3).
Desfecho (variável-alvo)			
sepse_tardia	sim_nao	Sim;Não	Ocorrência de sepse neonatal tardia

Variável	Tipo	Valores permitidos	Descrição / definição operacional
			(CID-10 A41.9 ou P36).
cid10_registrado	lista	A41.9;P36;Não se aplica	Código CID-10 registrado, se sepse_tardia = Sim.

PARTE III – FICHA DE COLETA DE DADOS

Preencher uma ficha por recém-nascido (um prontuário).

Variável	Valor coletado
ID	
id_prontuario	
data_coleta	
pesquisador	
Demográficas e do parto	
sexo_rn (Masculino;Feminino)	
idade_gestacional_semanas	
peso_nascimento_g	
apgar_1min	
apgar_5min	
tipo_parto (Vaginal;Cesariana)	
idade_materna	
raca_cor_rn (Branca;Preta;Parda;Amarela;Indígena;Não informado)	
raca_cor_mae (Branca;Preta;Parda;Amarela;Indígena;Não informado)	
num_gestacoes_anteriores	
itu_materna (Sim;Não)	
rotura_prematura_membranas (Sim;Não)	
corioamnionite (Sim;Não)	
pre_eclampsia (Sim;Não)	
atb_materno_intraparto (Sim;Não)	
Clínicas e de internação	
tempo_internacao_utin_dias	
vm_invasiva (Sim;Não)	
vm_invasiva_dias	
cateter_venoso_central (Sim;Não)	
cvc_dias	
cateter_umbilical (Sim;Não)	
npt (Sim;Não)	
npt_dias	
atb_previo_sepse_tardia (Sim;Não)	
classes_atb_usadas	
historia_sugestiva_infeccao (Sim;Não)	
criterios_disfuncao_organica (Sim;Não)	
enterocolite_necrosante (Sim;Não)	
hemorragia_intraventricular_grau (Ausente;I;II;III;IV)	
temperatura_min_c	
temperatura_max_c	
temperatura_media_c	

Variável	Valor coletado
frequencia_cardiaca_bpm	
frequencia_respiratoria_irpm	
spo2_pct	
pas_mmhg	
pad_mmhg	
uso_vasopressor (Sim;Não)	
droga_vasopressor	
surfactante_exogeno (Sim;Não)	
episodios_apneia_bradicardia_24h	
tempo_diagnostico_sepse_dias	
Laboratoriais	
leucocitos_totais	
neutrofilos_segmentados_pct	
neutrofilos_bastoes_pct	
relacao_it	
plaquetas	
pcr_mg_l	
pct_ng_ml	
glicemia_mg_dl	
creatinina_mg_dl	
bilirrubina_total_mg_dl	
ph_sangue	
lactato_mmol_l	
hemoglobina_g_dl	
hematocrito_pct	
sodio_meq_l	
potassio_meq_l	
calcio_ionizado_mmol_l	
tgo_u_l	
tgp_u_l	
relacao_neutrofilos_linfocitos	
Microbiológicas	
hemocultura_resultado (Positiva;Negativa;Não realizada)	
agente_isolado	
perfil_sensibilidade_atb	
historico_iras (Sim;Não)	
colonizacao_scn_klebsiella (Sim;Não)	
Escores clínicos	
glasgow_neonatal_adaptada	
news2_score	
qsofa_score	
Desfecho (variável-alvo)	

Variável	Valor coletado
sepse_tardia (Sim;Não)	
cid10_registrado (A41.9;P36;Não se aplica)	